

Mid-term Exam (Graph Neural Networks - Fall 2026)

문제지 ENG + KOR

Full Name:

Student ID:

Note: Students should write in English for evaluation.

1회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1$, $P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1$, $P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{C, D\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ -2 \\ 1 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = E$.
- Calculate $E_{p(u_j | E)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(E)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ -1 \\ 3 \\ 2 \\ 4 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.2$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.7$, $\gamma_1 = 0.3$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b) $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.

c) $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -3 \\ 3 \\ -1 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are
PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} 2 & -2 \\ 4 & -1 \\ 4 & 3 \\ 3 & 2 \end{bmatrix}$$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (B, C) and (A, C) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -3 \\ 3 \\ 2 \end{bmatrix}$$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = 1, u'_B = 0.5, u'_C = -1, u'_D = -0.5.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate $p_2(A|C)$, $p_2(B|C)$, $p_2(C|C)$ and $p_2(D|C)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 0 \\ 2 \\ 3 \\ -2 \end{bmatrix}$$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 2 \\ -3 \\ 2 \\ 1 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.2$, $\beta = 0.5$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -1 \\ 2 \\ -3 \\ 0 \end{bmatrix}$$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 3 \\ 3 \\ 1 \end{bmatrix}$$

2회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{D, E\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ -2 \\ 3 \\ 1 \\ -1 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = C$.
- Calculate $E_{p(u_j | C)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(C)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 4 \\ -1 \\ 2 \\ 2 \\ 1 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.5$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.7$, $\gamma_1 = 0.3$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 0 \\ -1 \\ -2 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b) $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.

c) $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 3 \\ 4 \\ -1 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} 0 & 4 \\ 1 & 3 \\ 1 & -2 \\ -2 & 1 \end{bmatrix}$$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (C, D) and (A, C) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = 1, u'_C = 0.5, u'_D = -1.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate $p_2(A|C)$, $p_2(B|C)$, $p_2(C|C)$ and $p_2(D|C)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ -2 \\ 2 \\ -2 \\ 4 \end{bmatrix}$$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 0 \\ -3 \\ -1 \\ -1 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.2$, $\beta = 0.4$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -3 \\ -1 \\ 1 \\ -1 \end{bmatrix}$$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 0 \\ 3 \\ 1 \end{bmatrix}$$

3회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{B, C\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 1 \\ 0 \\ -2 \\ -1 \\ 2 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = C$.
- Calculate $E_{p(u_j | C)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(C)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -1 \\ -1 \\ 4 \\ 1 \\ -2 \end{bmatrix}$$

ENG)

4. (APPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.5$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.5$, $\gamma_1 = 0.2$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ -1 \\ 4 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b) $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.

c) $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ -2 \\ 1 \\ -1 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are
PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} 4 & 0 \\ 1 & 3 \\ 1 & -1 \\ -1 & 4 \end{bmatrix}$$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (A, C) and (B, D) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -3 \\ 4 \\ 3 \end{bmatrix}$$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = 0.5, u'_C = 1, u'_D = -1.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate $p_2(A|B)$, $p_2(B|B)$, $p_2(C|B)$ and $p_2(D|B)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -2 \\ -1 \\ 4 \\ 4 \end{bmatrix}$$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -3 \\ -3 \\ -3 \\ 3 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.2$, $\beta = 0.4$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha)\tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 3 \\ 3 \\ 0 \\ -1 \end{bmatrix}$$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 1 \\ 2 \\ 0 \end{bmatrix}$$

4회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- a) Explain the key assumption behind relational classification, and state one limitation.
- b) Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- c) Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- a) 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- b) 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- c) 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{D, E\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 3 \\ 3 \\ 2 \\ 0 \\ 2 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = B$.
- Calculate $E_{p(u_j | B)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(B)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 0 \\ -1 \\ 2 \\ 4 \\ 2 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.2$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.5$, $\gamma_1 = 0.4$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 3 \\ -2 \\ 3 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b) $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.

c) $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ -2 \\ -2 \\ 3 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} -1 & 0 \\ 0 & 0 \\ 4 & 0 \\ -2 & 0 \end{bmatrix}$$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (A, D) and (A, C) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 0 \\ 3 \\ 3 \end{bmatrix}$$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = -1, u'_C = 0.5, u'_D = 1.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate $p_2(A|B)$, $p_2(B|B)$, $p_2(C|B)$ and $p_2(D|B)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ -3 \\ -2 \\ 2 \\ -2 \end{bmatrix}$$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 0 \\ 0 \\ -2 \\ 3 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.5$, $\beta = 0.5$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 4 \\ -2 \\ 3 \\ -1 \end{bmatrix}$$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ 0 \\ -2 \end{bmatrix}$$

5회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{B, E\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ 4 \\ 4 \\ -1 \\ -2 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = E$.
- Calculate $E_{p(u_j | E)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(E)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 4 \\ 4 \\ 1 \\ 2 \\ 3 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.2$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.7$, $\gamma_1 = 0.2$, $\gamma_2 = -0.3$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 1 \\ -2 \\ 2 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b) $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.

c) $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -3 \\ 1 \\ 0 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} -2 & 4 \\ 1 & -1 \\ -1 & 1 \\ -1 & 3 \end{bmatrix}$$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (C, D) and (A, D) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 2 \\ 1 \\ 0 \end{bmatrix}$$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

ENG)**10. (LINE)** Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = 0.5, u'_B = 1, u'_C = -1, u'_D = -0.5.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate $p_2(A|B)$, $p_2(B|B)$, $p_2(C|B)$ and $p_2(D|B)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

ENG)**11. (GCN)** Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ 4 \\ 0 \\ -1 \\ -3 \end{bmatrix}$$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -1 \\ 4 \\ 2 \\ -1 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.5$, $\beta = 0.4$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -3 \\ 3 \\ 4 \\ -1 \end{bmatrix}$$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 1 \\ 2 \\ 0 \end{bmatrix}$$