

# Mid-term Exam (Graph Neural Networks - Fall 2026)

문제지 ENG + KOR

Full Name:

Student ID:

Note: Students should write in English for evaluation.

## 1회차

ENG)

**1. (Relational Classification)** Consider an undirected graph  $G$  of five nodes given in the following figure. Nodes 1 and 5 are labelled ( $P(Y_1) = 1, P(Y_5) = 0$ ) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = ( \sum_{(v,u) \in E} A_{v,u} P(Y_u = c) ) / ( \sum_{(v,u) \in E} A_{v,u} )$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate  $P(Y_v)$  for every unlabelled node after the 1st iteration.
- Calculate  $P(Y_v)$  after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며( $P(Y_1)=1, P(Y_5)=0$ ), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의  $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의  $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

**2. (FastGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left( \frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where  $\tilde{A} = D^{-1}A$  and the  $t_l$  nodes are drawn once per layer from  $q(u) \propto \|\tilde{A}(:, u)\|^2$ , with  $\text{ReLU}(x) = \max(0, x)$ .

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution  $q(u)$  over the five nodes.
- Suppose the sampled set is  $\{C, D\}$  ( $t_l = 2$ ). Calculate the estimate of  $h^{(1)}(A)$ .

KOR)

인접행렬  $A$  와 노드 특징 벡터  $h^{(0)}$  가 주어진 무방향 그래프  $G$  를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서  $t_l$  개의 노드를 중요도 분포  $q(u) \propto \|A(:, u)\|^2$  로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수  $t_l$  로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포  $q(u)$  를 계산하시오.
- 주어진 추출 집합( $t_l = 2$ )에 대하여  $h^{(1)}(A)$  의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ -2 \\ 1 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma( W^{(l)} N(v_i) E_{p(u_j | v_i)}[ h^{(l)}(u_j) ] )$$

where  $\tilde{A} = D^{-1}A$ ,  $N(v_i) = \sum_j \tilde{A}_{ij}$ ,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ ,  $W^{(l)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate  $N(v_i)$  and  $p(u_j | v_i)$  for the parent node  $v_i = E$ .
- Calculate  $E_{p(u_j | E)}[h^{(0)}(u_j)]$  and the resulting  $h^{(1)}(E)$ .

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서  $N(v_i) = \sum_j \tilde{A}_{ij}$  는 정규화 계수이고,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$  는 부모 노드  $v_i$  가 주어졌을 때 노드  $u_j$  를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한  $N(v_i)$  와  $p(u_j | v_i)$  를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는  $h^{(1)}$  을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ -1 \\ 3 \\ 2 \\ 4 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix  $A$  and a prediction matrix  $H$  produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability  $\alpha$ :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where  $\tilde{A} = D^{-1}A$  and  $\alpha = 0.2$ . No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate  $\tilde{A}$  and  $Z^{(1)}$ .
- Calculate  $Z^{(2)}$ .

KOR)

인접행렬  $A$  와 다층 퍼셉트론이 산출한 예측 행렬  $H$  가 주어졌다.

APPPNP 는 순간이동 확률  $\alpha$  를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$  와  $Z^{(1)}$  을 계산하시오.
- $Z^{(2)}$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix  $A$  and hidden features  $H^{(0)}$  as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where  $\tilde{A} = D^{-1}A$ ,  $K = 2$ ,  $\gamma_0 = 0.7$ ,  $\gamma_1 = 0.3$ ,  $\gamma_2 = -0.2$ .

- What can GPR-GNN do that APPNP cannot, and why do negative  $\gamma_k$  matter?
- Calculate  $H^{(1)}$  and  $H^{(2)}$ .
- Calculate  $Z$ .

KOR)

인접행렬  $A$  와 신경망이 산출한 은닉 특징  $H^{(0)}$  이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다.  $\tilde{A}$  를 반복 적용하여  $H^{(k)}$  를 얻고, 학습된 가중치  $\gamma_k$  로 가중합한다. 본 문항에서는  $K = 2$  이며  $\gamma_0, \gamma_1, \gamma_2$  가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며,  $\gamma_k$  가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$  과  $H^{(2)}$  를 계산하시오.
- $Z$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where  $P = \{0, 1, 2\}$ ,  $\hat{A} = D^{-1}A$ ,  $W_j^{(i)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$  and  $\hat{A}^2 H^{(0)}$ .
- Calculate  $H^{(1)}$  and the Delta Operator  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱  $\hat{A}^j$  ( $j \in P = \{0, 1, 2\}$ )를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b)  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$ ,  $\hat{A}^2 H^{(0)}$  을 계산하시오.

c)  $H^{(1)}$  과 델타 연산자  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -3 \\ 3 \\ -1 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with  $s = 1$  and  $n = 4$ .

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final  $x_i$ .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬  $X$  가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다.  $s = 1, n = 4$  로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종  $x_i$  를 계산하시오.

$$X = \begin{bmatrix} 2 & -2 \\ 4 & -1 \\ 4 & 3 \\ 3 & 2 \end{bmatrix}$$

ENG)

**8. (DropEdge)** Consider the complete graph  $K_4$  on nodes A, B, C and D with the adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  below.

DropEdge keeps each undirected edge independently with probability  $1 - p$  at every epoch:

$$H^{(1)} = \sigma( (D^{(t)})^{-1} A^{(t)} H^{(0)} )$$

where  $A^{(t)}$  and  $D^{(t)}$  are rebuilt from the surviving edges only,  $p = 1/3$ , and  $\text{ReLU}(x) = \max(0, x)$ .

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and  $H^{(1)}$  on the full graph.
- Suppose the edges (B, C) and (A, C) are dropped. Recalculate  $H^{(1)}$ .

KOR)

노드 A, B, C, D 로 이루어진 완전그래프  $K_4$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률  $1-p$  로 독립적으로 유지한다. 이때  $A^{(t)}$  와  $D^{(t)}$  는 살아남은 간선만으로 다시 구성한다.  $p = 1/3$  으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의  $H^{(1)}$  을 계산하시오.
- 주어진 두 간선이 제거되었을 때의  $H^{(1)}$  을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -3 \\ 3 \\ 2 \end{bmatrix}$$

ENG)

**9. (Node2vec)** Consider an undirected graph  $G$  given in the following figure. A random walk has just moved from node  $A$  to node  $B$ , with  $p = 2$  and  $q = 0.5$ .

The unnormalized transition probability from  $B$  to a next node  $x$  is  $\pi_{Bx} = \alpha_{pq}(A, x)$ , where  $\alpha = 1/p$  if  $d(A, x) = 0$ ,  $\alpha = 1$  if  $d(A, x) = 1$ , and  $\alpha = 1/q$  if  $d(A, x) = 2$ .

- Explain BFS and DFS, and explain which one a small  $q$  makes the walk behave like.
- List all possible next nodes from node  $B$  and calculate  $\pi_{Bx}$ .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프  $G$  를 고려한다. 임의보행이 노드  $A$  에서 노드  $B$  로 이동하여 현재  $B$  에 있으며,  $p = 2, q = 0.5$  이다.

$B$  에서 다음 노드  $x$  로의 비정규화 전이확률은  $\pi_{Bx} = \alpha_{pq}(A, x)$  이며,  $\alpha$  는 직전 노드  $A$  로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고,  $q$  가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드  $B$  에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률  $\pi_{Bx}$  를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

**ENG)**

**10. (LINE)** Consider an undirected graph  $G$  with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = 1, u'_B = 0.5, u'_C = -1, u'_D = -0.5.$$

The second-order proximity is  $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ . Given  $e^{0.25} = 1.28$ ,  $e^{0.5} = 1.65$ ,  $e^{-0.25} = 0.78$ ,  $e^{-0.5} = 0.61$ .

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate  $p_2(A|C)$ ,  $p_2(B|C)$ ,  $p_2(C|C)$  and  $p_2(D|C)$ .

**KOR)**

노드 임베딩  $u$  와 맥락 임베딩  $u'$  가 주어진 무방향 그래프  $G$  를 고려한다.

2차 근접도는  $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$  로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의  $p_2$  를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the hidden layer of a GCN model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how information is propagated in a GCN layer.
- Calculate  $\tilde{A}$ .
- Calculate the output of the GCN model at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCN 모형의 층  $(k)$  에서의 은닉층은  $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$  로 계산된다고 가정한다. 여기서  $\tilde{A} = D^{-1}A$  는 정규화된 인접행렬이고  $\sigma$  는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 0 \\ 2 \\ 3 \\ -2 \end{bmatrix}$$

ENG)

**12. (GraphSAGE)** Consider an undirected graph  $G$  of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at  $k = 1$ .
- Calculate a graph-level embedding  $h_G$  by using a 'Mean' global pooling when  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드  $i$ 의 층  $k$  특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩  $h_G$ 를 계산하시오.




Figure. Graph G

ENG)

**13. (ClusterGCN)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  contains two clusters  $G_1$  and  $G_2$ . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 는 두 개의 군집  $G_1$  과  $G_2$  를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층  $k = 1$  에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**14. (GraphSAINT)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  has a sampled subgraph  $G_1$ . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 에는 추출된 부분그래프  $G_1$ 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층  $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**15. (JK Network)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a JK network model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \max( \sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}) )$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate  $\tilde{A}$  and  $H^{(1)}$ .
- Calculate the output representations at layer  $k = 2$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

JK 신경망의 층  $(k)$  출력은  $\sigma(\tilde{A} H^{(0)})$  부터  $\sigma(\tilde{A} H^{(k-1)})$  까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$  와  $H^{(1)}$  을 계산하시오.
- 층  $k = 2$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 2 \\ -3 \\ 2 \\ 1 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a GCNII model of all nodes at layer ( $k$ ) can be calculated as:

$$H^{(k)} = \sigma[ ((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)}) ]$$

where  $\tilde{A} = D^{-1}A$ ,  $I_n$  is the identity matrix,  $\alpha = 0.2$ ,  $\beta = 0.5$ , and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate  $\tilde{A}$ .
- Calculate the output representations at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCNII 모형의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma[ ((1-\beta)I_n) \cdot ((1-\alpha)\tilde{A} H^{(k-1)} + \alpha H^{(0)}) ]$  로 계산된다고 가정한다.  $I_n$  은 단위행렬이며  $\alpha$  와  $\beta$  는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -1 \\ 2 \\ -3 \\ 0 \end{bmatrix}$$

ENG)

**17. (DeepGCN)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a DeepGCN model with a residual connection at layer  $(k)$  is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer  $k = 1$  and  $k = 2$ .
- Compare  $H^{(1)}$  with the output of a plain GCN without the residual connection.

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층  $(k)$  출력은  $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$  로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층  $k = 1$  과  $k = 2$  에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과  $H^{(1)}$  을 비교하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 3 \\ 3 \\ 1 \end{bmatrix}$$

## 2회차

ENG)

**1. (Relational Classification)** Consider an undirected graph  $G$  of five nodes given in the following figure. Nodes 1 and 5 are labelled ( $P(Y_1) = 1, P(Y_5) = 0$ ) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = ( \sum_{(v,u) \in E} A_{v,u} P(Y_u = c) ) / ( \sum_{(v,u) \in E} A_{v,u} )$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate  $P(Y_v)$  for every unlabelled node after the 1st iteration.
- Calculate  $P(Y_v)$  after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며( $P(Y_1)=1, P(Y_5)=0$ ), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의  $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의  $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

**2. (FastGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left( \frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where  $\tilde{A} = D^{-1}A$  and the  $t_l$  nodes are drawn once per layer from  $q(u) \propto \|\tilde{A}(:, u)\|^2$ , with  $\text{ReLU}(x) = \max(0, x)$ .

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution  $q(u)$  over the five nodes.
- Suppose the sampled set is  $\{D, E\}$  ( $t_l = 2$ ). Calculate the estimate of  $h^{(1)}(A)$ .

KOR)

인접행렬  $A$  와 노드 특징 벡터  $h^{(0)}$  가 주어진 무방향 그래프  $G$  를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서  $t_l$  개의 노드를 중요도 분포  $q(u) \propto \|A(:, u)\|^2$  로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수  $t_l$  로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포  $q(u)$  를 계산하시오.
- 주어진 추출 집합( $t_l = 2$ )에 대하여  $h^{(1)}(A)$  의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ -2 \\ 3 \\ 1 \\ -1 \end{bmatrix}$$

**ENG)**

**3. (ASGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma( W^{(l)} N(v_i) E_{p(u_j | v_i)}[ h^{(l)}(u_j) ] )$$

where  $\tilde{A} = D^{-1}A$ ,  $N(v_i) = \sum_j \tilde{A}_{ij}$ ,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ ,  $W^{(l)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate  $N(v_i)$  and  $p(u_j | v_i)$  for the parent node  $v_i = C$ .
- Calculate  $E_{p(u_j | C)}[h^{(0)}(u_j)]$  and the resulting  $h^{(1)}(C)$ .

**KOR)**

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서  $N(v_i) = \sum_j \tilde{A}_{ij}$  는 정규화 계수이고,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$  는 부모 노드  $v_i$  가 주어졌을 때 노드  $u_j$  를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한  $N(v_i)$  와  $p(u_j | v_i)$  를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는  $h^{(1)}$  을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 4 \\ -1 \\ 2 \\ 2 \\ 1 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix  $A$  and a prediction matrix  $H$  produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability  $\alpha$ :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where  $\tilde{A} = D^{-1}A$  and  $\alpha = 0.5$ . No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate  $\tilde{A}$  and  $Z^{(1)}$ .
- Calculate  $Z^{(2)}$ .

KOR)

인접행렬  $A$  와 다층 퍼셉트론이 산출한 예측 행렬  $H$  가 주어졌다.

APPPNP 는 순간이동 확률  $\alpha$  를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$  와  $Z^{(1)}$  을 계산하시오.
- $Z^{(2)}$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix  $A$  and hidden features  $H^{(0)}$  as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where  $\tilde{A} = D^{-1}A$ ,  $K = 2$ ,  $\gamma_0 = 0.7$ ,  $\gamma_1 = 0.3$ ,  $\gamma_2 = -0.2$ .

- What can GPR-GNN do that APPNP cannot, and why do negative  $\gamma_k$  matter?
- Calculate  $H^{(1)}$  and  $H^{(2)}$ .
- Calculate  $Z$ .

KOR)

인접행렬  $A$  와 신경망이 산출한 은닉 특징  $H^{(0)}$  이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다.  $\tilde{A}$  를 반복 적용하여  $H^{(k)}$  를 얻고, 학습된 가중치  $\gamma_k$  로 가중합한다. 본 문항에서는  $K = 2$  이며  $\gamma_0, \gamma_1, \gamma_2$  가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며,  $\gamma_k$  가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$  과  $H^{(2)}$  를 계산하시오.
- $Z$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 0 \\ -1 \\ -2 \end{bmatrix}$$

ENG)

**6. (MixHop)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where  $P = \{0, 1, 2\}$ ,  $\hat{A} = D^{-1}A$ ,  $W_j^{(i)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$  and  $\hat{A}^2 H^{(0)}$ .
- Calculate  $H^{(1)}$  and the Delta Operator  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱  $\hat{A}^j$  ( $j \in P = \{0, 1, 2\}$ )를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b)  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$ ,  $\hat{A}^2 H^{(0)}$  을 계산하시오.

c)  $H^{(1)}$  과 델타 연산자  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 3 \\ 4 \\ -1 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with  $s = 1$  and  $n = 4$ .

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final  $x_i$ .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬  $X$  가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다.  $s = 1, n = 4$  로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종  $x_i$  를 계산하시오.

$$X = \begin{bmatrix} 0 & 4 \\ 1 & 3 \\ 1 & -2 \\ -2 & 1 \end{bmatrix}$$

ENG)

**8. (DropEdge)** Consider the complete graph  $K_4$  on nodes A, B, C and D with the adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  below.

DropEdge keeps each undirected edge independently with probability  $1 - p$  at every epoch:

$$H^{(1)} = \sigma( (D^{(t)})^{-1} A^{(t)} H^{(0)} )$$

where  $A^{(t)}$  and  $D^{(t)}$  are rebuilt from the surviving edges only,  $p = 1/3$ , and  $\text{ReLU}(x) = \max(0, x)$ .

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and  $H^{(1)}$  on the full graph.
- Suppose the edges (C, D) and (A, C) are dropped. Recalculate  $H^{(1)}$ .

KOR)

노드 A, B, C, D 로 이루어진 완전그래프  $K_4$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률  $1-p$  로 독립적으로 유지한다. 이때  $A^{(t)}$  와  $D^{(t)}$  는 살아남은 간선만으로 다시 구성한다.  $p = 1/3$  으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의  $H^{(1)}$  을 계산하시오.
- 주어진 두 간선이 제거되었을 때의  $H^{(1)}$  을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

ENG)

**9. (Node2vec)** Consider an undirected graph  $G$  given in the following figure. A random walk has just moved from node  $A$  to node  $B$ , with  $p = 2$  and  $q = 0.5$ .

The unnormalized transition probability from  $B$  to a next node  $x$  is  $\pi_{Bx} = \alpha_{pq}(A, x)$ , where  $\alpha = 1/p$  if  $d(A, x) = 0$ ,  $\alpha = 1$  if  $d(A, x) = 1$ , and  $\alpha = 1/q$  if  $d(A, x) = 2$ .

- Explain BFS and DFS, and explain which one a small  $q$  makes the walk behave like.
- List all possible next nodes from node  $B$  and calculate  $\pi_{Bx}$ .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프  $G$  를 고려한다. 임의보행이 노드  $A$  에서 노드  $B$  로 이동하여 현재  $B$  에 있으며,  $p = 2, q = 0.5$  이다.

$B$  에서 다음 노드  $x$  로의 비정규화 전이확률은  $\pi_{Bx} = \alpha_{pq}(A, x)$  이며,  $\alpha$  는 직전 노드  $A$  로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고,  $q$  가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드  $B$  에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률  $\pi_{Bx}$  를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph  $G$

**ENG)**

**10. (LINE)** Consider an undirected graph  $G$  with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = 1, u'_C = 0.5, u'_D = -1.$$

The second-order proximity is  $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ . Given  $e^{0.25} = 1.28$ ,  $e^{0.5} = 1.65$ ,  $e^{-0.25} = 0.78$ ,  $e^{-0.5} = 0.61$ .

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate  $p_2(A|C)$ ,  $p_2(B|C)$ ,  $p_2(C|C)$  and  $p_2(D|C)$ .

**KOR)**

노드 임베딩  $u$  와 맥락 임베딩  $u'$  가 주어진 무방향 그래프  $G$  를 고려한다.

2차 근접도는  $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$  로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의  $p_2$  를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the hidden layer of a GCN model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how information is propagated in a GCN layer.
- Calculate  $\tilde{A}$ .
- Calculate the output of the GCN model at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCN 모형의 층  $(k)$  에서의 은닉층은  $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$  로 계산된다고 가정한다. 여기서  $\tilde{A} = D^{-1}A$  는 정규화된 인접행렬이고  $\sigma$  는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ -2 \\ 2 \\ -2 \\ 4 \end{bmatrix}$$

ENG)

**12. (GraphSAGE)** Consider an undirected graph  $G$  of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at  $k = 1$ .
- Calculate a graph-level embedding  $h_G$  by using a 'Mean' global pooling when  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드  $i$ 의 층  $k$  특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩  $h_G$ 를 계산하시오.




Figure. Graph G

ENG)

**13. (ClusterGCN)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  contains two clusters  $G_1$  and  $G_2$ . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 는 두 개의 군집  $G_1$  과  $G_2$  를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층  $k = 1$  에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**14. (GraphSAINT)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  has a sampled subgraph  $G_1$ . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 에는 추출된 부분그래프  $G_1$ 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층  $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**15. (JK Network)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a JK network model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \max( \sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}) )$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate  $\tilde{A}$  and  $H^{(1)}$ .
- Calculate the output representations at layer  $k = 2$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

JK 신경망의 층  $(k)$  출력은  $\sigma(\tilde{A} H^{(0)})$  부터  $\sigma(\tilde{A} H^{(k-1)})$  까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$  와  $H^{(1)}$  을 계산하시오.
- 층  $k = 2$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 0 \\ -3 \\ -1 \\ -1 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a GCNII model of all nodes at layer ( $k$ ) can be calculated as:

$$H^{(k)} = \sigma[ ((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)}) ]$$

where  $\tilde{A} = D^{-1}A$ ,  $I_n$  is the identity matrix,  $\alpha = 0.2$ ,  $\beta = 0.4$ , and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate  $\tilde{A}$ .
- Calculate the output representations at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCNII 모형의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma[ ((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)}) ]$  로 계산된다고 가정한다.  $I_n$  은 단위행렬이며  $\alpha$  와  $\beta$  는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -3 \\ -1 \\ 1 \\ -1 \end{bmatrix}$$

ENG)

**17. (DeepGCN)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a DeepGCN model with a residual connection at layer ( $k$ ) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer  $k = 1$  and  $k = 2$ .
- Compare  $H^{(1)}$  with the output of a plain GCN without the residual connection.

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$  로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층  $k = 1$  과  $k = 2$  에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과  $H^{(1)}$  을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 0 \\ 3 \\ 1 \end{bmatrix}$$

### 3회차

ENG)

**1. (Relational Classification)** Consider an undirected graph  $G$  of five nodes given in the following figure. Nodes 1 and 5 are labelled ( $P(Y_1) = 1, P(Y_5) = 0$ ) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = ( \sum_{(v,u) \in E} A_{v,u} P(Y_u = c) ) / ( \sum_{(v,u) \in E} A_{v,u} )$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate  $P(Y_v)$  for every unlabelled node after the 1st iteration.
- Calculate  $P(Y_v)$  after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며( $P(Y_1)=1, P(Y_5)=0$ ), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의  $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의  $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

**2. (FastGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left( \frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where  $\tilde{A} = D^{-1}A$  and the  $t_l$  nodes are drawn once per layer from  $q(u) \propto \|\tilde{A}(:, u)\|^2$ , with  $\text{ReLU}(x) = \max(0, x)$ .

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution  $q(u)$  over the five nodes.
- Suppose the sampled set is  $\{B, C\}$  ( $t_l = 2$ ). Calculate the estimate of  $h^{(1)}(A)$ .

KOR)

인접행렬  $A$  와 노드 특징 벡터  $h^{(0)}$  가 주어진 무방향 그래프  $G$  를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서  $t_l$  개의 노드를 중요도 분포  $q(u) \propto \|A(:, u)\|^2$  로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수  $t_l$  로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포  $q(u)$  를 계산하시오.
- 주어진 추출 집합( $t_l = 2$ )에 대하여  $h^{(1)}(A)$  의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 1 \\ 0 \\ -2 \\ -1 \\ 2 \end{bmatrix}$$

**ENG)**

**3. (ASGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma( W^{(l)} N(v_i) E_{p(u_j | v_i)}[ h^{(l)}(u_j) ] )$$

where  $\tilde{A} = D^{-1}A$ ,  $N(v_i) = \sum_j \tilde{A}_{ij}$ ,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ ,  $W^{(l)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate  $N(v_i)$  and  $p(u_j | v_i)$  for the parent node  $v_i = C$ .
- Calculate  $E_{p(u_j | C)}[h^{(0)}(u_j)]$  and the resulting  $h^{(1)}(C)$ .

**KOR)**

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서  $N(v_i) = \sum_j \tilde{A}_{ij}$  는 정규화 계수이고,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$  는 부모 노드  $v_i$  가 주어졌을 때 노드  $u_j$  를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한  $N(v_i)$  와  $p(u_j | v_i)$  를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는  $h^{(1)}$  을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -1 \\ -1 \\ 4 \\ 1 \\ -2 \end{bmatrix}$$

ENG)

4. (APPNP) Given a graph with an adjacency matrix  $A$  and a prediction matrix  $H$  produced by an MLP as follows:

APPNP propagates the predictions with a teleport probability  $\alpha$ :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where  $\tilde{A} = D^{-1}A$  and  $\alpha = 0.5$ . No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate  $\tilde{A}$  and  $Z^{(1)}$ .
- Calculate  $Z^{(2)}$ .

KOR)

인접행렬  $A$  와 다층 퍼셉트론이 산출한 예측 행렬  $H$  가 주어졌다.

APPNP 는 순간이동 확률  $\alpha$  를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$  와  $Z^{(1)}$  을 계산하시오.
- $Z^{(2)}$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix  $A$  and hidden features  $H^{(0)}$  as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where  $\tilde{A} = D^{-1}A$ ,  $K = 2$ ,  $\gamma_0 = 0.5$ ,  $\gamma_1 = 0.2$ ,  $\gamma_2 = -0.2$ .

- What can GPR-GNN do that APPNP cannot, and why do negative  $\gamma_k$  matter?
- Calculate  $H^{(1)}$  and  $H^{(2)}$ .
- Calculate  $Z$ .

KOR)

인접행렬  $A$  와 신경망이 산출한 은닉 특징  $H^{(0)}$  이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다.  $\tilde{A}$  를 반복 적용하여  $H^{(k)}$  를 얻고, 학습된 가중치  $\gamma_k$  로 가중합한다. 본 문항에서는  $K = 2$  이며  $\gamma_0, \gamma_1, \gamma_2$  가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며,  $\gamma_k$  가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$  과  $H^{(2)}$  를 계산하시오.
- $Z$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ -1 \\ 4 \end{bmatrix}$$

ENG)

**6. (MixHop)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where  $P = \{0, 1, 2\}$ ,  $\hat{A} = D^{-1}A$ ,  $W_j^{(i)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$  and  $\hat{A}^2 H^{(0)}$ .
- Calculate  $H^{(1)}$  and the Delta Operator  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱  $\hat{A}^j$  ( $j \in P = \{0, 1, 2\}$ )를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b)  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$ ,  $\hat{A}^2 H^{(0)}$  을 계산하시오.

c)  $H^{(1)}$  과 델타 연산자  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ -2 \\ 1 \\ -1 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are  
PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with  $s = 1$  and  $n = 4$ .

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final  $x_i$ .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬  $X$  가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다.  $s = 1, n = 4$  로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종  $x_i$  를 계산하시오.

$$X = \begin{bmatrix} 4 & 0 \\ 1 & 3 \\ 1 & -1 \\ -1 & 4 \end{bmatrix}$$

ENG)

**8. (DropEdge)** Consider the complete graph  $K_4$  on nodes A, B, C and D with the adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  below.

DropEdge keeps each undirected edge independently with probability  $1 - p$  at every epoch:

$$H^{(1)} = \sigma( (D^{(t)})^{-1} A^{(t)} H^{(0)} )$$

where  $A^{(t)}$  and  $D^{(t)}$  are rebuilt from the surviving edges only,  $p = 1/3$ , and  $\text{ReLU}(x) = \max(0, x)$ .

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and  $H^{(1)}$  on the full graph.
- Suppose the edges (A, C) and (B, D) are dropped. Recalculate  $H^{(1)}$ .

KOR)

노드 A, B, C, D 로 이루어진 완전그래프  $K_4$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률  $1-p$  로 독립적으로 유지한다. 이때  $A^{(t)}$  와  $D^{(t)}$  는 살아남은 간선만으로 다시 구성한다.  $p = 1/3$  으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의  $H^{(1)}$  을 계산하시오.
- 주어진 두 간선이 제거되었을 때의  $H^{(1)}$  을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -3 \\ 4 \\ 3 \end{bmatrix}$$

ENG)

**9. (Node2vec)** Consider an undirected graph  $G$  given in the following figure. A random walk has just moved from node  $A$  to node  $B$ , with  $p = 2$  and  $q = 0.5$ .

The unnormalized transition probability from  $B$  to a next node  $x$  is  $\pi_{Bx} = \alpha_{pq}(A, x)$ , where  $\alpha = 1/p$  if  $d(A, x) = 0$ ,  $\alpha = 1$  if  $d(A, x) = 1$ , and  $\alpha = 1/q$  if  $d(A, x) = 2$ .

- Explain BFS and DFS, and explain which one a small  $q$  makes the walk behave like.
- List all possible next nodes from node  $B$  and calculate  $\pi_{Bx}$ .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프  $G$  를 고려한다. 임의보행이 노드  $A$  에서 노드  $B$  로 이동하여 현재  $B$  에 있으며,  $p = 2, q = 0.5$  이다.

$B$  에서 다음 노드  $x$  로의 비정규화 전이확률은  $\pi_{Bx} = \alpha_{pq}(A, x)$  이며,  $\alpha$  는 직전 노드  $A$  로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고,  $q$  가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드  $B$  에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률  $\pi_{Bx}$  를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph  $G$

**ENG)**

**10. (LINE)** Consider an undirected graph  $G$  with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = 0.5, u'_C = 1, u'_D = -1.$$

The second-order proximity is  $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ . Given  $e^{0.25} = 1.28$ ,  $e^{0.5} = 1.65$ ,  $e^{-0.25} = 0.78$ ,  $e^{-0.5} = 0.61$ .

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate  $p_2(A|B)$ ,  $p_2(B|B)$ ,  $p_2(C|B)$  and  $p_2(D|B)$ .

**KOR)**

노드 임베딩  $u$  와 맥락 임베딩  $u'$  가 주어진 무방향 그래프  $G$  를 고려한다.

2차 근접도는  $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$  로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의  $p_2$  를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the hidden layer of a GCN model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how information is propagated in a GCN layer.
- Calculate  $\tilde{A}$ .
- Calculate the output of the GCN model at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCN 모형의 층  $(k)$  에서의 은닉층은  $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$  로 계산된다고 가정한다. 여기서  $\tilde{A} = D^{-1}A$  는 정규화된 인접행렬이고  $\sigma$  는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -2 \\ -1 \\ 4 \\ 4 \end{bmatrix}$$

ENG)

**12. (GraphSAGE)** Consider an undirected graph  $G$  of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at  $k = 1$ .
- Calculate a graph-level embedding  $h_G$  by using a 'Mean' global pooling when  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드  $i$ 의 층  $k$  특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩  $h_G$ 를 계산하시오.




Figure. Graph G

ENG)

**13. (ClusterGCN)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  contains two clusters  $G_1$  and  $G_2$ . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 는 두 개의 군집  $G_1$  과  $G_2$  를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층  $k = 1$  에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph  $G$

ENG)

**14. (GraphSAINT)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  has a sampled subgraph  $G_1$ . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 에는 추출된 부분그래프  $G_1$ 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층  $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**15. (JK Network)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a JK network model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate  $\tilde{A}$  and  $H^{(1)}$ .
- Calculate the output representations at layer  $k = 2$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

JK 신경망의 층  $(k)$  출력은  $\sigma(\tilde{A} H^{(0)})$  부터  $\sigma(\tilde{A} H^{(k-1)})$  까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$  와  $H^{(1)}$  을 계산하시오.
- 층  $k = 2$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -3 \\ -3 \\ -3 \\ 3 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a GCNII model of all nodes at layer ( $k$ ) can be calculated as:

$$H^{(k)} = \sigma[ ((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)}) ]$$

where  $\tilde{A} = D^{-1}A$ ,  $I_n$  is the identity matrix,  $\alpha = 0.2$ ,  $\beta = 0.4$ , and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate  $\tilde{A}$ .
- Calculate the output representations at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCNII 모형의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma[ ((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)}) ]$  로 계산된다고 가정한다.  $I_n$  은 단위행렬이며  $\alpha$  와  $\beta$  는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 3 \\ 3 \\ 0 \\ -1 \end{bmatrix}$$

ENG)

**17. (DeepGCN)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a DeepGCN model with a residual connection at layer ( $k$ ) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer  $k = 1$  and  $k = 2$ .
- Compare  $H^{(1)}$  with the output of a plain GCN without the residual connection.

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$  로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층  $k = 1$  과  $k = 2$  에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과  $H^{(1)}$  을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 1 \\ 2 \\ 0 \end{bmatrix}$$

## 4회차

**ENG)**

**1. (Relational Classification)** Consider an undirected graph  $G$  of five nodes given in the following figure. Nodes 1 and 5 are labelled ( $P(Y_1) = 1, P(Y_5) = 0$ ) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = ( \sum_{(v,u) \in E} A_{v,u} P(Y_u = c) ) / ( \sum_{(v,u) \in E} A_{v,u} )$$

- a) Explain the key assumption behind relational classification, and state one limitation.
- b) Calculate  $P(Y_v)$  for every unlabelled node after the 1st iteration.
- c) Calculate  $P(Y_v)$  after the 2nd iteration, using the previous iteration's values only.

**KOR)**

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며( $P(Y_1)=1, P(Y_5)=0$ ), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- a) 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- b) 1차 반복 후 이름표가 없는 각 노드의  $P(Y_v)$ 를 계산하시오.
- c) 2차 반복 후의  $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

**2. (FastGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left( \frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where  $\tilde{A} = D^{-1}A$  and the  $t_l$  nodes are drawn once per layer from  $q(u) \propto \|\tilde{A}(:, u)\|^2$ , with  $\text{ReLU}(x) = \max(0, x)$ .

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution  $q(u)$  over the five nodes.
- Suppose the sampled set is  $\{D, E\}$  ( $t_l = 2$ ). Calculate the estimate of  $h^{(1)}(A)$ .

KOR)

인접행렬  $A$  와 노드 특징 벡터  $h^{(0)}$  가 주어진 무방향 그래프  $G$  를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서  $t_l$  개의 노드를 중요도 분포  $q(u) \propto \|A(:, u)\|^2$  로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수  $t_l$  로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포  $q(u)$  를 계산하시오.
- 주어진 추출 집합( $t_l = 2$ )에 대하여  $h^{(1)}(A)$  의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 3 \\ 3 \\ 2 \\ 0 \\ 2 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma( W^{(l)} N(v_i) E_{p(u_j | v_i)}[ h^{(l)}(u_j) ] )$$

where  $\tilde{A} = D^{-1}A$ ,  $N(v_i) = \sum_j \tilde{A}_{ij}$ ,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ ,  $W^{(l)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate  $N(v_i)$  and  $p(u_j | v_i)$  for the parent node  $v_i = B$ .
- Calculate  $E_{p(u_j | B)}[h^{(0)}(u_j)]$  and the resulting  $h^{(1)}(B)$ .

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서  $N(v_i) = \sum_j \tilde{A}_{ij}$  는 정규화 계수이고,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$  는 부모 노드  $v_i$  가 주어졌을 때 노드  $u_j$  를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한  $N(v_i)$  와  $p(u_j | v_i)$  를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는  $h^{(1)}$  을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 0 \\ -1 \\ 2 \\ 4 \\ 2 \end{bmatrix}$$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix  $A$  and a prediction matrix  $H$  produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability  $\alpha$ :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where  $\tilde{A} = D^{-1}A$  and  $\alpha = 0.2$ . No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate  $\tilde{A}$  and  $Z^{(1)}$ .
- Calculate  $Z^{(2)}$ .

KOR)

인접행렬  $A$  와 다층 퍼셉트론이 산출한 예측 행렬  $H$  가 주어졌다.

APPPNP 는 순간이동 확률  $\alpha$  를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$  와  $Z^{(1)}$  을 계산하시오.
- $Z^{(2)}$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix  $A$  and hidden features  $H^{(0)}$  as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where  $\tilde{A} = D^{-1}A$ ,  $K = 2$ ,  $\gamma_0 = 0.5$ ,  $\gamma_1 = 0.4$ ,  $\gamma_2 = -0.2$ .

- What can GPR-GNN do that APPNP cannot, and why do negative  $\gamma_k$  matter?
- Calculate  $H^{(1)}$  and  $H^{(2)}$ .
- Calculate  $Z$ .

KOR)

인접행렬  $A$  와 신경망이 산출한 은닉 특징  $H^{(0)}$  이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다.  $\tilde{A}$  를 반복 적용하여  $H^{(k)}$  를 얻고, 학습된 가중치  $\gamma_k$  로 가중합한다. 본 문항에서는  $K = 2$  이며  $\gamma_0, \gamma_1, \gamma_2$  가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며,  $\gamma_k$  가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$  과  $H^{(2)}$  를 계산하시오.
- $Z$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 3 \\ -2 \\ 3 \end{bmatrix}$$

ENG)

6. (MixHop) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where  $P = \{0, 1, 2\}$ ,  $\hat{A} = D^{-1}A$ ,  $W_j^{(i)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$  and  $\hat{A}^2 H^{(0)}$ .
- Calculate  $H^{(1)}$  and the Delta Operator  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱  $\hat{A}^j$  ( $j \in P = \{0, 1, 2\}$ )를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b)  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$ ,  $\hat{A}^2 H^{(0)}$  을 계산하시오.

c)  $H^{(1)}$  과 델타 연산자  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ -2 \\ -2 \\ 3 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with  $s = 1$  and  $n = 4$ .

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final  $x_i$ .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬  $X$  가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다.  $s = 1, n = 4$  로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종  $x_i$  를 계산하시오.

$$X = \begin{bmatrix} -1 & 0 \\ 0 & 0 \\ 4 & 0 \\ -2 & 0 \end{bmatrix}$$

ENG)

**8. (DropEdge)** Consider the complete graph  $K_4$  on nodes A, B, C and D with the adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  below.

DropEdge keeps each undirected edge independently with probability  $1 - p$  at every epoch:

$$H^{(1)} = \sigma( (D^{(t)})^{-1} A^{(t)} H^{(0)} )$$

where  $A^{(t)}$  and  $D^{(t)}$  are rebuilt from the surviving edges only,  $p = 1/3$ , and  $\text{ReLU}(x) = \max(0, x)$ .

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and  $H^{(1)}$  on the full graph.
- Suppose the edges (A, D) and (A, C) are dropped. Recalculate  $H^{(1)}$ .

KOR)

노드 A, B, C, D 로 이루어진 완전그래프  $K_4$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률  $1-p$  로 독립적으로 유지한다. 이때  $A^{(t)}$  와  $D^{(t)}$  는 살아남은 간선만으로 다시 구성한다.  $p = 1/3$  으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의  $H^{(1)}$  을 계산하시오.
- 주어진 두 간선이 제거되었을 때의  $H^{(1)}$  을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 0 \\ 3 \\ 3 \end{bmatrix}$$

ENG)

**9. (Node2vec)** Consider an undirected graph  $G$  given in the following figure. A random walk has just moved from node  $A$  to node  $B$ , with  $p = 2$  and  $q = 0.5$ .

The unnormalized transition probability from  $B$  to a next node  $x$  is  $\pi_{Bx} = \alpha_{pq}(A, x)$ , where  $\alpha = 1/p$  if  $d(A, x) = 0$ ,  $\alpha = 1$  if  $d(A, x) = 1$ , and  $\alpha = 1/q$  if  $d(A, x) = 2$ .

- Explain BFS and DFS, and explain which one a small  $q$  makes the walk behave like.
- List all possible next nodes from node  $B$  and calculate  $\pi_{Bx}$ .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프  $G$  를 고려한다. 임의보행이 노드  $A$  에서 노드  $B$  로 이동하여 현재  $B$  에 있으며,  $p = 2, q = 0.5$  이다.

$B$  에서 다음 노드  $x$  로의 비정규화 전이확률은  $\pi_{Bx} = \alpha_{pq}(A, x)$  이며,  $\alpha$  는 직전 노드  $A$  로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고,  $q$  가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드  $B$  에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률  $\pi_{Bx}$  를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph  $G$

**ENG)**

**10. (LINE)** Consider an undirected graph  $G$  with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = -1, u'_C = 0.5, u'_D = 1.$$

The second-order proximity is  $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ . Given  $e^{0.25} = 1.28$ ,  $e^{0.5} = 1.65$ ,  $e^{-0.25} = 0.78$ ,  $e^{-0.5} = 0.61$ .

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate  $p_2(A|B)$ ,  $p_2(B|B)$ ,  $p_2(C|B)$  and  $p_2(D|B)$ .

**KOR)**

노드 임베딩  $u$  와 맥락 임베딩  $u'$  가 주어진 무방향 그래프  $G$  를 고려한다.

2차 근접도는  $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$  로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의  $p_2$  를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the hidden layer of a GCN model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how information is propagated in a GCN layer.
- Calculate  $\tilde{A}$ .
- Calculate the output of the GCN model at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCN 모형의 층  $(k)$  에서의 은닉층은  $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$  로 계산된다고 가정한다. 여기서  $\tilde{A} = D^{-1}A$  는 정규화된 인접행렬이고  $\sigma$  는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ -3 \\ -2 \\ 2 \\ -2 \end{bmatrix}$$

ENG)

**12. (GraphSAGE)** Consider an undirected graph  $G$  of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at  $k = 1$ .
- Calculate a graph-level embedding  $h_G$  by using a 'Mean' global pooling when  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드  $i$ 의 층  $k$  특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩  $h_G$ 를 계산하시오.




Figure. Graph G

ENG)

**13. (ClusterGCN)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  contains two clusters  $G_1$  and  $G_2$ . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 는 두 개의 군집  $G_1$  과  $G_2$  를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층  $k = 1$  에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**14. (GraphSAINT)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  has a sampled subgraph  $G_1$ . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 에는 추출된 부분그래프  $G_1$ 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층  $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**15. (JK Network)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a JK network model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate  $\tilde{A}$  and  $H^{(1)}$ .
- Calculate the output representations at layer  $k = 2$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

JK 신경망의 층  $(k)$  출력은  $\sigma(\tilde{A} H^{(0)})$  부터  $\sigma(\tilde{A} H^{(k-1)})$  까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$  와  $H^{(1)}$  을 계산하시오.
- 층  $k = 2$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 0 \\ 0 \\ -2 \\ 3 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a GCNII model of all nodes at layer ( $k$ ) can be calculated as:

$$H^{(k)} = \sigma[ ((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)}) ]$$

where  $\tilde{A} = D^{-1}A$ ,  $I_n$  is the identity matrix,  $\alpha = 0.5$ ,  $\beta = 0.5$ , and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate  $\tilde{A}$ .
- Calculate the output representations at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCNII 모형의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma[ ((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)}) ]$  로 계산된다고 가정한다.  $I_n$  은 단위행렬이며  $\alpha$  와  $\beta$  는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 4 \\ -2 \\ 3 \\ -1 \end{bmatrix}$$

ENG)

**17. (DeepGCN)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a DeepGCN model with a residual connection at layer ( $k$ ) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer  $k = 1$  and  $k = 2$ .
- Compare  $H^{(1)}$  with the output of a plain GCN without the residual connection.

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$  로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층  $k = 1$  과  $k = 2$  에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과  $H^{(1)}$  을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ 0 \\ -2 \end{bmatrix}$$

## 5회차

ENG)

**1. (Relational Classification)** Consider an undirected graph  $G$  of five nodes given in the following figure. Nodes 1 and 5 are labelled ( $P(Y_1) = 1, P(Y_5) = 0$ ) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = ( \sum_{(v,u) \in E} A_{v,u} P(Y_u = c) ) / ( \sum_{(v,u) \in E} A_{v,u} )$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate  $P(Y_v)$  for every unlabelled node after the 1st iteration.
- Calculate  $P(Y_v)$  after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며( $P(Y_1)=1, P(Y_5)=0$ ), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의  $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의  $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

ENG)

**2. (FastGCN)** Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left( \frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where  $\tilde{A} = D^{-1}A$  and the  $t_l$  nodes are drawn once per layer from  $q(u) \propto \|\tilde{A}(:, u)\|^2$ , with  $\text{ReLU}(x) = \max(0, x)$ .

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution  $q(u)$  over the five nodes.
- Suppose the sampled set is  $\{B, E\}$  ( $t_l = 2$ ). Calculate the estimate of  $h^{(1)}(A)$ .

KOR)

인접행렬  $A$  와 노드 특징 벡터  $h^{(0)}$  가 주어진 무방향 그래프  $G$  를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서  $t_l$  개의 노드를 중요도 분포  $q(u) \propto \|A(:, u)\|^2$  로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수  $t_l$  로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포  $q(u)$  를 계산하시오.
- 주어진 추출 집합( $t_l = 2$ )에 대하여  $h^{(1)}(A)$  의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ 4 \\ 4 \\ -1 \\ -2 \end{bmatrix}$$

ENG)

3. (ASGCN) Consider the undirected graph  $G$  with adjacency matrix  $A$  and node feature vector  $h^{(0)}$  below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma( W^{(l)} N(v_i) E_{p(u_j | v_i)}[ h^{(l)}(u_j) ] )$$

where  $\tilde{A} = D^{-1}A$ ,  $N(v_i) = \sum_j \tilde{A}_{ij}$ ,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ ,  $W^{(l)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate  $N(v_i)$  and  $p(u_j | v_i)$  for the parent node  $v_i = E$ .
- Calculate  $E_{p(u_j | E)}[h^{(0)}(u_j)]$  and the resulting  $h^{(1)}(E)$ .

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서  $N(v_i) = \sum_j \tilde{A}_{ij}$  는 정규화 계수이고,  $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$  는 부모 노드  $v_i$  가 주어졌을 때 노드  $u_j$  를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한  $N(v_i)$  와  $p(u_j | v_i)$  를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는  $h^{(1)}$  을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 4 \\ 4 \\ 1 \\ 2 \\ 3 \end{bmatrix}$$

ENG)

4. (APPNP) Given a graph with an adjacency matrix  $A$  and a prediction matrix  $H$  produced by an MLP as follows:

APPNP propagates the predictions with a teleport probability  $\alpha$ :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where  $\tilde{A} = D^{-1}A$  and  $\alpha = 0.2$ . No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate  $\tilde{A}$  and  $Z^{(1)}$ .
- Calculate  $Z^{(2)}$ .

KOR)

인접행렬  $A$  와 다층 퍼셉트론이 산출한 예측 행렬  $H$  가 주어졌다.

APPNP 는 순간이동 확률  $\alpha$  를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$  와  $Z^{(1)}$  을 계산하시오.
- $Z^{(2)}$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix  $A$  and hidden features  $H^{(0)}$  as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where  $\tilde{A} = D^{-1}A$ ,  $K = 2$ ,  $\gamma_0 = 0.7$ ,  $\gamma_1 = 0.2$ ,  $\gamma_2 = -0.3$ .

- What can GPR-GNN do that APPNP cannot, and why do negative  $\gamma_k$  matter?
- Calculate  $H^{(1)}$  and  $H^{(2)}$ .
- Calculate  $Z$ .

KOR)

인접행렬  $A$  와 신경망이 산출한 은닉 특징  $H^{(0)}$  이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다.  $\tilde{A}$  를 반복 적용하여  $H^{(k)}$  를 얻고, 학습된 가중치  $\gamma_k$  로 가중합한다. 본 문항에서는  $K = 2$  이며  $\gamma_0, \gamma_1, \gamma_2$  가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며,  $\gamma_k$  가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$  과  $H^{(2)}$  를 계산하시오.
- $Z$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 1 \\ -2 \\ 2 \end{bmatrix}$$

ENG)

**6. (MixHop)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where  $P = \{0, 1, 2\}$ ,  $\hat{A} = D^{-1}A$ ,  $W_j^{(i)} = 1$  and  $\text{ReLU}(x) = \max(0, x)$ .

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$  and  $\hat{A}^2 H^{(0)}$ .
- Calculate  $H^{(1)}$  and the Delta Operator  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱  $\hat{A}^j$  ( $j \in P = \{0, 1, 2\}$ )를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b)  $\hat{A}^0 H^{(0)}$ ,  $\hat{A}^1 H^{(0)}$ ,  $\hat{A}^2 H^{(0)}$  을 계산하시오.

c)  $H^{(1)}$  과 델타 연산자  $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$  를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -3 \\ 1 \\ 0 \end{bmatrix}$$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with  $s = 1$  and  $n = 4$ .

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final  $x_i$ .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬  $X$  가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다.  $s = 1, n = 4$  로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종  $x_i$  를 계산하시오.

$$X = \begin{bmatrix} -2 & 4 \\ 1 & -1 \\ -1 & 1 \\ -1 & 3 \end{bmatrix}$$

ENG)

**8. (DropEdge)** Consider the complete graph  $K_4$  on nodes A, B, C and D with the adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  below.

DropEdge keeps each undirected edge independently with probability  $1 - p$  at every epoch:

$$H^{(1)} = \sigma( (D^{(t)})^{-1} A^{(t)} H^{(0)} )$$

where  $A^{(t)}$  and  $D^{(t)}$  are rebuilt from the surviving edges only,  $p = 1/3$ , and  $\text{ReLU}(x) = \max(0, x)$ .

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and  $H^{(1)}$  on the full graph.
- Suppose the edges (C, D) and (A, D) are dropped. Recalculate  $H^{(1)}$ .

KOR)

노드 A, B, C, D 로 이루어진 완전그래프  $K_4$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률  $1-p$  로 독립적으로 유지한다. 이때  $A^{(t)}$  와  $D^{(t)}$  는 살아남은 간선만으로 다시 구성한다.  $p = 1/3$  으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의  $H^{(1)}$  을 계산하시오.
- 주어진 두 간선이 제거되었을 때의  $H^{(1)}$  을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 2 \\ 1 \\ 0 \end{bmatrix}$$

ENG)

**9. (Node2vec)** Consider an undirected graph  $G$  given in the following figure. A random walk has just moved from node  $A$  to node  $B$ , with  $p = 2$  and  $q = 0.5$ .

The unnormalized transition probability from  $B$  to a next node  $x$  is  $\pi_{Bx} = \alpha_{pq}(A, x)$ , where  $\alpha = 1/p$  if  $d(A, x) = 0$ ,  $\alpha = 1$  if  $d(A, x) = 1$ , and  $\alpha = 1/q$  if  $d(A, x) = 2$ .

- Explain BFS and DFS, and explain which one a small  $q$  makes the walk behave like.
- List all possible next nodes from node  $B$  and calculate  $\pi_{Bx}$ .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프  $G$  를 고려한다. 임의보행이 노드  $A$  에서 노드  $B$  로 이동하여 현재  $B$  에 있으며,  $p = 2, q = 0.5$  이다.

$B$  에서 다음 노드  $x$  로의 비정규화 전이확률은  $\pi_{Bx} = \alpha_{pq}(A, x)$  이며,  $\alpha$  는 직전 노드  $A$  로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고,  $q$  가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드  $B$  에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률  $\pi_{Bx}$  를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph  $G$

**ENG)****10. (LINE)** Consider an undirected graph  $G$  with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = 0.5, u'_B = 1, u'_C = -1, u'_D = -0.5.$$

The second-order proximity is  $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ . Given  $e^{0.25} = 1.28$ ,  $e^{0.5} = 1.65$ ,  $e^{-0.25} = 0.78$ ,  $e^{-0.5} = 0.61$ .

- a) What is second-order proximity, and how does it differ from first-order proximity?
- b) Calculate  $p_2(A|B)$ ,  $p_2(B|B)$ ,  $p_2(C|B)$  and  $p_2(D|B)$ .

**KOR)**

노드 임베딩  $u$  와 맥락 임베딩  $u'$  가 주어진 무방향 그래프  $G$  를 고려한다.

2차 근접도는  $p_2(j | x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$  로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- a) 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- b) 주어진 기준 노드에 대하여 네 노드의  $p_2$  를 계산하시오.

ENG)

11. (GCN) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the hidden layer of a GCN model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how information is propagated in a GCN layer.
- Calculate  $\tilde{A}$ .
- Calculate the output of the GCN model at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCN 모형의 층  $(k)$  에서의 은닉층은  $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$  로 계산된다고 가정한다. 여기서  $\tilde{A} = D^{-1}A$  는 정규화된 인접행렬이고  $\sigma$  는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ 4 \\ 0 \\ -1 \\ -3 \end{bmatrix}$$

ENG)

**12. (GraphSAGE)** Consider an undirected graph  $G$  of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at  $k = 1$ .
- Calculate a graph-level embedding  $h_G$  by using a 'Mean' global pooling when  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드  $i$ 의 층  $k$  특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩  $h_G$ 를 계산하시오.




Figure. Graph G

ENG)

**13. (ClusterGCN)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  contains two clusters  $G_1$  and  $G_2$ . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 는 두 개의 군집  $G_1$  과  $G_2$  를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층  $k = 1$  에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**14. (GraphSAINT)** Consider an undirected graph  $G$  of six nodes given in the following figure. The graph  $G$  has a sampled subgraph  $G_1$ . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node  $i$  at layer  $k$  can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}( h_i^{(k-1)} \parallel h_{N(i)}^{(k)} )$$

where  $\parallel$  is a concatenation and  $\text{ReLU}(x) = \max(0, x)$ .

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer  $k = 1$ .

KOR)

다음 그림의 무방향 그래프  $G$ (노드 6개)를 고려한다. 그래프  $G$ 에는 추출된 부분그래프  $G_1$ 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층  $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

ENG)

**15. (JK Network)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a JK network model of all nodes at layer  $(k)$  can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate  $\tilde{A}$  and  $H^{(1)}$ .
- Calculate the output representations at layer  $k = 2$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

JK 신경망의 층  $(k)$  출력은  $\sigma(\tilde{A} H^{(0)})$  부터  $\sigma(\tilde{A} H^{(k-1)})$  까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$  와  $H^{(1)}$  을 계산하시오.
- 층  $k = 2$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -1 \\ 4 \\ 2 \\ -1 \end{bmatrix}$$

ENG)

16. (GCNII) Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a GCNII model of all nodes at layer ( $k$ ) can be calculated as:

$$H^{(k)} = \sigma[ ((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)}) ]$$

where  $\tilde{A} = D^{-1}A$ ,  $I_n$  is the identity matrix,  $\alpha = 0.5$ ,  $\beta = 0.4$ , and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate  $\tilde{A}$ .
- Calculate the output representations at layer  $k = 1$ .

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

GCNII 모형의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma[ ((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)}) ]$  로 계산된다고 가정한다.  $I_n$  은 단위행렬이며  $\alpha$  와  $\beta$  는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$  를 계산하시오.
- 층  $k = 1$  에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -3 \\ 3 \\ 4 \\ -1 \end{bmatrix}$$

ENG)

**17. (DeepGCN)** Given a graph with an adjacency matrix  $A$  and initial node feature matrix  $H^{(0)}$  as follows:

Assume that the output of a DeepGCN model with a residual connection at layer ( $k$ ) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where  $\tilde{A} = D^{-1}A$  and  $\sigma$  is a ReLU function  $\text{ReLU}(x) = \max(0, x)$ .

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer  $k = 1$  and  $k = 2$ .
- Compare  $H^{(1)}$  with the output of a plain GCN without the residual connection.

KOR)

인접행렬  $A$  와 초기 노드 특징 행렬  $H^{(0)}$  이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 ( $k$ ) 출력은  $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$  로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층  $k = 1$  과  $k = 2$  에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과  $H^{(1)}$  을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 1 \\ 2 \\ 0 \end{bmatrix}$$