

Mid-term Exam (Graph Neural Networks - Fall 2026)

해설지 ENG + KOR

Full Name:

Student ID:

Note: Students should write in English for evaluation.

1회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Relational classification assumes homophily: connected nodes tend to share the same label.
 - It repeatedly sets each unlabelled node to the weighted average of its neighbours' class probabilities.
 - Its limitation is that it uses only the graph structure and ignores node features.

KOR)

a) 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.

- 관계형 분류는 동질성을 가정해요. 이어진 노드끼리는 같은 이름표를 가지는 경향이 있다는 뜻이에요.

- 이름표 없는 노드를 이웃들의 확률의 가중 평균으로 거듭 바꿔요.

- 한계는 그래프 구조만 쓰고 노드의 특징은 무시한다는 것이에요.

ENG) b) $P(Y1) = 1$, $P(Y2) = 0.6667$, $P(Y3) = 0.25$, $P(Y4) = 0.5$, $P(Y5) = 0$

ENG) c) $P(Y1) = 1$, $P(Y2) = 0.5833$, $P(Y3) = 0.3333$, $P(Y4) = 0.5556$, $P(Y5) = 0$

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{C, D\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ -2 \\ 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In node-wise sampling, each node samples its own neighbours, so the cost grows exponentially with depth.
 - FastGCN samples a fixed-size set of nodes once per layer, shared by all nodes in that layer.
 - Therefore the cost grows only linearly with depth instead of exponentially.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 뽑기는 노드마다 제 이웃을 뽑아서, 층이 깊어질수록 비용이 지수로 커져요.
 - FastGCN 은 층마다 정해진 개수를 한 번만 뽑고, 그 층의 모든 노드가 같이 써요.
 - 그래서 비용이 지수가 아니라 층 수에 비례해서만 늘어요.

ENG) b) $q(A) = 0.6237$, $q(B) = 0.0672$, $q(C) = 0.0672$, $q(D) = 0.2177$, $q(E) = 0.0242$

ENG) c) $h^{(1)}(A) = 0$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = E$.
- Calculate $E_{p(u_j | E)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(E)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ -1 \\ 3 \\ 2 \\ 4 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In FastGCN the sampling distribution is fixed in advance and does not depend on the parent nodes.
 - In ASGCN the proposal distribution is conditioned on the nodes of the upper layer.
 - This makes almost every sampled node useful and reduces the variance of the estimate.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - FastGCN 의 뽑기 확률은 미리 정해져 있고 부모 노드와 상관이 없어요.
 - ASGCN 은 뽑기 확률을 윗층 노드에 맞춰 정해요.
 - 그래서 뽑은 노드가 거의 다 쓸모 있고, 추정값의 흔들림이 줄어요.

ENG) b) $N(E) = 1$, $p(B|E) = 0.3333$, $p(C|E) = 0.3333$, $p(D|E) = 0.3333$

ENG) c) $E = 1.3333$, $h1(E) = 1.3333$

ENG)

4. (APPP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.2$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - At every propagation step the walk returns to the root node with probability alpha. This is the teleport mechanism.
 - Because a fixed fraction of the mass is pulled back at every step, the distribution stays local.
 - So we can use many propagation steps without over-smoothing, and propagation has no extra parameters.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 퍼뜨리는 걸음마다 확률 알파로 출발 노드로 되돌아가요. 이것이 순간이동 장치예요.
 - 매 걸음 일정 비율이 되돌아오니까 분포가 출발점 근처에 머물러요.
 - 그래서 많이 퍼뜨려도 과평활이 안 생기고, 퍼뜨리는 데에 추가 파라미터도 없어요.

ENG) b) $\tilde{A} = [0, 0.5, 0.5, 0]; [0.5, 0, 0, 0.5]; [0.5, 0, 0, 0.5]; [0, 0.5, 0.5, 0]$

ENG) $Z^1 = [0.4, 0.2, 0, 0.4]$

ENG) c) $Z^2 = [0.08, 0.52, 0.32, 0.08]$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.7$, $\gamma_1 = 0.3$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - APPNP fixes the coefficients to alpha times (1-alpha) to the power k, which are always positive and decreasing.
 - GPR-GNN learns the weights, and they are allowed to be negative.
 - A negative weight subtracts that hop, so the model can act as a high-pass filter on heterophilic graphs.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - APPNP 는 계수를 알파 곱하기 (1-알파)의 k제곱으로 못 박아요. 늘 양수이고 줄어들어요.
 - GPR-GNN 은 그 무게를 학습하고, 음수도 될 수 있어요.
 - 음수 무게는 그 걸음을 빼요. 그래서 이질 그래프에서 고주파 필터처럼 동작할 수 있어요.

ENG) b) $H_1 = [0, 3, 3, 0]$, $H_2 = [3, 0, 0, 3]$

ENG) c) $Z = [2.2, -0.5, 2.3, 0.8]$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다. 본 문항에서 가중치 행렬은 모두 1로 둔다.

- 두 걸음 델타 연산자에 관한 MixHop의 정리 1을 서술하고, 보통의 GCN이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.
- $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.
- $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -3 \\ 3 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Theorem 1 says that a vanilla GCN cannot represent the two-hop Delta Operator, even with infinitely many layers.
 - Stacking GCN layers collapses to $\hat{A}$ to the power l times W , so the intermediate hops are never kept separately.
 - MixHop computes each power separately and concatenates them, so a later layer can subtract one from another.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 정리 1은 보통 GCN이 두 걸음 델타 연산자를 표현할 수 없다고 말해요. 층을 무한히 쌓아도요.
 - GCN 층을 쌓으면 A 에 1제곱 곱하기 W 꼴로 뭉쳐져서, 중간 걸음들이 따로 남지 않아요.
 - MixHop은 거듭제곱마다 따로 구해서 나란히 붙여요. 그래서 뒤 층이 하나에서 다른 하나를 뺄 수 있어요.

ENG) b) $A^0 H = [1, -3, 3, -1]$, $A^1 H = [-3, 1, -2, 0]$, $A^2 H = [1, -1.6667, 0.5, -0.5]$

ENG) c) $H^1 = \text{concatenation of the three blocks: } [1, 0, 3, 0] \parallel [0, 1, 0, 0] \parallel [1, 0, 0.5, 0]$

KOR) c) H1 = 세 조각을 이어 붙여요: $[1, 0, 3, 0] \mid [0, 1, 0, 0] \mid [1, 0, 0.5, 0]$

ENG) $\Delta = [-1, 1, -0.5, 0]$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are

PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} 2 & -2 \\ 4 & -1 \\ 4 & 3 \\ 3 & 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Node-wise over-smoothing means the features of connected nodes become too similar.
 - Feature-wise over-smoothing means all node features become indistinguishable across the whole graph.
 - PairNorm keeps the total pairwise squared distance between node representations constant across layers.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 과평활은 이어진 노드들의 특징이 너무 비슷해지는 것이에요.
 - 특징 단위 과평활은 그래프 전체에서 모든 노드 특징이 구별이 안 되게 되는 것이에요.
 - PairNorm 은 층을 지나도 노드 사이 거리 제곱의 합을 일정하게 지켜요.

ENG) b) Mean = [3.25, 0.5], centered = [-1.25, -2.5]; [0.75, -1.5]; [0.75, 2.5]; [-0.25, 1.5]

KOR) b) 평균 = [3.25, 0.5], 중심을 뺀 것 = [-1.25, -2.5]; [0.75, -1.5]; [0.75, 2.5]; [-0.25, 1.5]

ENG) c) Scaling denominator = 2.222, $x = [-0.5625, -1.1251]; [0.3375, -0.6751]; [0.3375, 1.1251]; [-0.1125, 0.6751]$

KOR) c) 분모 = 2.222, $x = [-0.5625, -1.1251]; [0.3375, -0.6751]; [0.3375, 1.1251]; [-0.1125, 0.6751]$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (B, C) and (A, C) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -3 \\ 3 \\ 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - DropEdge targets over-fitting and over-smoothing.
 - A different random subgraph is used at every epoch, which works as data augmentation on the graph.
 - Dropout zeroes entries of the feature tensor, while DropEdge removes edges of the adjacency matrix.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - DropEdge 는 과적합과 과평활을 노려요.
 - 판마다 다른 부분 그래프를 써요. 그래프에 자료를 늘리는 효과가 나요.
 - Dropout 은 특징 값을 0 으로 꺼요. DropEdge 는 인접행렬의 선을 지워요.

ENG) b) Expected number of surviving edges = 4, $H_1 = [0.6667, 2.6667, 0.6667, 1]$

KOR) b) 남는 선 수의 기댓값 = 4, $H_1 = [0.6667, 2.6667, 0.6667, 1]$

ENG) c) $H_1 = [0, 2.5, 2, 1]$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

풀이

ENG)

- Write these three sentences.
 - BFS explores the immediate neighbourhood first, so the embedding captures the structural role of a node.
 - DFS moves far away from the source, so the embedding captures community membership.
 - A small q makes $1/q$ large, so the walk moves outward and behaves like DFS.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - BFS 는 바로 옆 이웃부터 훑어요. 그래서 임베딩이 노드의 구조적 역할을 담아요.
 - DFS 는 출발점에서 멀리 가요. 그래서 임베딩이 어느 동네 소속인지를 담아요.
 - q 가 작으면 $1/q$ 가 커져서 걸음이 바깥으로 나가요. DFS 처럼 움직여요.

ENG) b) $\pi(B \rightarrow A) = 0.5$, $\pi(B \rightarrow C) = 2$, $\pi(B \rightarrow E) = 2$

ENG) c) $P(A) = 0.1111$, $P(C) = 0.4444$, $P(E) = 0.4444$

ENG)**10. (LINE)** Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = 1, u'_B = 0.5, u'_C = -1, u'_D = -0.5.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate $p_2(A|C)$, $p_2(B|C)$, $p_2(C|C)$ and $p_2(D|C)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

풀이**ENG)**

- Write these three sentences.
 - First-order proximity is the similarity between two nodes that are directly connected by an edge.
 - Second-order proximity is the similarity between two nodes that share many neighbours, even without an edge.
 - So LINE gives each node two vectors: its own embedding and its context embedding.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 1차 근접도는 선으로 직접 이어진 두 노드 사이의 비슷함이에요.
 - 2차 근접도는 이웃을 많이 공유하는 두 노드의 비슷함이에요. 선이 없어도 돼요.
 - 그래서 LINE 은 노드마다 벡터를 두 개 뒹요. 자기 벡터와 맥락 벡터예요.

ENG) b) $p_2(A|C) = 0.1412$, $p_2(B|C) = 0.1806$, $p_2(C|C) = 0.3819$, $p_2(D|C) = 0.2963$

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 0 \\ 2 \\ 3 \\ -2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In one layer each node aggregates the features of its direct neighbours and takes the average.
 - The row-normalized matrix $\tilde{A}$ equals $D^{-1}A$, which performs this averaging.
 - After k layers a node has received information from all nodes within k hops.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 한 층에서 노드는 바로 옆 이웃의 특징을 모아 평균을 내요.
 - 행 정규화 행렬 $\tilde{A}$ 는 D 의 역행렬 곱하기 A 이고, 그것이 평균을 내 줘요.
 - k 개 층을 지나면 노드는 k 걸음 안의 모든 노드 정보를 받아요.

ENG) b) $\tilde{A} = [0, 0, 0.5, 0.5, 0]; [0, 0, 0.5, 0.5, 0]; [0.25, 0.25, 0, 0.25, 0.25]; [0.3333, 0.3333, 0.3333, 0, 0]; [0, 0, 1, 0, 0]$

ENG) c) $H_1 = [2.5, 2.5, 0.75, 1.3333, 2]$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE learns an aggregator function instead of a fixed embedding for each node.
 - It samples a fixed number of neighbours, so it can be trained in mini-batches on very large graphs.
 - A GCN is transductive, but GraphSAGE is inductive, so it can embed a node that was never seen in training.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE는 노드마다 고정된 벡터를 배우는 대신 모으는 함수를 배워요.
 - 이웃을 정해진 개수만 뽑아요. 그래서 아주 큰 그래프에서도 미니배치로 학습할 수 있어요.
 - GCN은 전이적이고 GraphSAGE는 귀납적이에요. 그래서 학습 때 못 본 노드도 벡터를 만들 수 있어요.

ENG) b) $h(A) = [3, 0.5]$, $h(B) = [4, 0.5]$, $h(C) = [0, 3.25]$, $h(D) = [2, 2]$, $h(E) = [4, 0]$

ENG) c) hG = [2.6, 1.25]

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Mini-batch training updates the parameters using a small subset of the data at a time.
 - A large graph does not fit in memory, so ClusterGCN partitions the graph into densely connected clusters.
 - A good partition keeps most edges inside a batch, so little information is lost at the boundary.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 미니배치 학습은 한 번에 자료의 일부만 써서 파라미터를 고쳐요.
 - 큰 그래프는 메모리에 안 들어가요. 그래서 ClusterGCN 은 안쪽이 촘촘한 덩어리로 나뉘요.
 - 잘 나누면 선 대부분이 배치 안에 남아서 경계에서 잃는 정보가 적어요.

ENG) b) $h(A) = [2, 0]$, $h(B) = [0, 0]$, $h(C) = [0, 1]$, $h(D) = [4, 2]$, $h(E) = [3, 2.5]$, $h(F) = [1, 3.5]$

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE and FastGCN sample while building the layers, so sampling is repeated at every layer.
 - GraphSAINT samples a subgraph first and then builds the full GNN on that subgraph.
 - So the cost does not grow with depth, and normalization coefficients correct the sampling bias.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE와 FastGCN은 층을 쌓으면서 뽑아요. 그래서 층마다 뽑기를 되풀이해요.
 - GraphSAINT는 부분 그래프를 먼저 뽑고 그 위에 GNN을 통째로 올려요.
 - 그래서 깊어져도 비용이 안 늘고, 정규화 계수로 뽑기의 치우침을 바로잡아요.

ENG) b) $h(A) = [0, 2.5]$, $h(B) = [4, 3]$, $h(C) = [2, 0]$, $h(D) = [3, 1.5]$

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 2 \\ -3 \\ 2 \\ 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In a deep GCN every node repeatedly averages its neighbours, so all representations become similar. This is over-smoothing.
 - JKNet keeps the representation of every layer and combines them at the end by max, concatenation or an LSTM.
 - The best depth is different for each node, so each node can select the depth that suits it.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 에서는 노드가 이웃 평균을 거듭 내서 표현들이 다 비슷해져요. 이것이 과평활이에요.
 - JKNet 은 모든 층의 표현을 들고 있다가 끝에서 최댓값, 이어 붙이기, LSTM 으로 합쳐요.
 - 알맞은 깊이는 노드마다 달라요. 그래서 노드마다 자기에게 맞는 깊이를 고를 수 있어요.

ENG) b) $\tilde{A} = [0, 0.3333, 0.3333, 0.3333, 0]; [0.3333, 0, 0, 0.3333, 0.3333]; [0.5, 0, 0, 0.5, 0]; [0.3333, 0.3333, 0.3333, 0, 0]; [0, 1, 0, 0, 0]$

ENG) H1 = [0.3333, 0.3333, 0, 0, 2]

ENG) c) H2 = [0.3333, 0.7778, 0.1667, 0.2222, 2]

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.2$, $\beta = 0.5$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha)\tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -1 \\ 2 \\ -3 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - The two components are the initial residual connection and the identity mapping.
 - The initial residual connection adds a fraction alpha of the input H zero back at every layer.
 - The identity mapping keeps the weight matrix close to the identity, so a deep model is not destroyed.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 두 장치는 초기 잔차 연결과 항등 사상이에요.
 - 초기 잔차 연결은 층마다 입력 $H^{(0)}$ 의 일부를 알파만큼 다시 더해요.
 - 항등 사상은 가중치 행렬을 단위행렬에 가깝게 뒹요. 그래서 깊어져도 신호가 안 망가져요.

ENG) b) $A_{ilde} = [0, 0, 0.3333, 0.3333, 0.3333]; [0, 0, 0, 0, 1]; [0.5, 0, 0, 0.5, 0]; [0.3333, 0, 0.3333, 0, 0.3333]; [0.3333, 0.3333, 0, 0.3333, 0]$

ENG) c) $H_1 = [0.1667, 0, 0.2, 0.3667, 0]$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 3 \\ 3 \\ 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Deep GCNs suffer from vanishing gradients and over-smoothing, so adding layers makes the model worse.
 - A residual connection passes the input forward unchanged, so each layer only has to learn the change.
 - If no change is useful the layer can output zero, and gradients also flow back through the skip path.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 은 기울기 소실과 과평활을 겪어요. 그래서 층을 더하면 오히려 나빠져요.
 - 잔차 연결은 입력을 그대로 앞으로 보내요. 그래서 층은 바뀌는 양만 배우면 돼요.
 - 바꿀 게 없으면 층은 0 을 내보내면 돼요. 기울기도 그 지름길로 되돌아 흘러요.

ENG) b) $H_1 = [1, 5, 4, 2.6667]$

ENG) $H_2 = [4.3333, 8.3333, 6.8889, 6]$

ENG) c) Plain GCN without residual: $H_1 = [2, 2, 1, 1.6667]$ (the node's own value and negatives disappear)

KOR) c) 잔차 없는 GCN 의 $H_1 = [2, 2, 1, 1.6667]$ (잔차가 없으면 자기 값과 음수가 사라져요)

2회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Relational classification assumes homophily: connected nodes tend to share the same label.
 - It repeatedly sets each unlabelled node to the weighted average of its neighbours' class probabilities.
 - Its limitation is that it uses only the graph structure and ignores node features.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 관계형 분류는 동질성을 가정해요. 이어진 노드끼리는 같은 이름표를 가지는 경향이 있다는 뜻이에요.
 - 이름표 없는 노드를 이웃들의 확률의 가중 평균으로 거듭 바뀌어요.
 - 한계는 그래프 구조만 쓰고 노드의 특징은 무시한다는 것이에요.

ENG) b) $P(Y_1) = 1, P(Y_2) = 0.6667, P(Y_3) = 0.75, P(Y_4) = 0.75, P(Y_5) = 0$

ENG) c) $P(Y_1) = 1, P(Y_2) = 0.8333, P(Y_3) = 0.8333, P(Y_4) = 0.8333, P(Y_5) = 0$

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{D, E\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ -2 \\ 3 \\ 1 \\ -1 \end{bmatrix}$$

풀이**ENG)**

- Write these three sentences.
 - In node-wise sampling, each node samples its own neighbours, so the cost grows exponentially with depth.
 - FastGCN samples a fixed-size set of nodes once per layer, shared by all nodes in that layer.
 - Therefore the cost grows only linearly with depth instead of exponentially.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 뽑기는 노드마다 제 이웃을 뽑아서, 층이 깊어질수록 비용이 지수로 커져요.
 - FastGCN 은 층마다 정해진 개수를 한 번만 뽑고, 그 층의 모든 노드가 같이 써요.
 - 그래서 비용이 지수가 아니라 층 수에 비례해서만 늘어요.

ENG) b) $q(A) = 0.4889$, $q(B) = 0.1889$, $q(C) = 0.0444$, $q(D) = 0.1889$, $q(E) = 0.0889$

ENG) c) $h^1(A) = 0.1667$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = C$.
- Calculate $E_{p(u_j | C)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(C)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 4 \\ -1 \\ 2 \\ 2 \\ 1 \end{bmatrix}$$

풀이**ENG)**

- Write these three sentences.
 - In FastGCN the sampling distribution is fixed in advance and does not depend on the parent nodes.
 - In ASGCN the proposal distribution is conditioned on the nodes of the upper layer.
 - This makes almost every sampled node useful and reduces the variance of the estimate.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - FastGCN 의 뽑기 확률은 미리 정해져 있고 부모 노드와 상관이 없어요.
 - ASGCN 은 뽑기 확률을 윗층 노드에 맞춰 정해요.
 - 그래서 뽑은 노드가 거의 다 쓸모 있고, 추정값의 흔들림이 줄어요.

ENG) b) $N(C) = 1$, $p(A|C) = 0.3333$, $p(D|C) = 0.3333$, $p(E|C) = 0.3333$

ENG) c) $E = 2.3333$, $h_1(C) = 2.3333$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.5$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - At every propagation step the walk returns to the root node with probability alpha. This is the teleport mechanism.
 - Because a fixed fraction of the mass is pulled back at every step, the distribution stays local.
 - So we can use many propagation steps without over-smoothing, and propagation has no extra parameters.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 퍼뜨리는 걸음마다 확률 알파로 출발 노드로 되돌아가요. 이것이 순간이동 장치예요.
 - 매 걸음 일정 비율이 되돌아오니까 분포가 출발점 근처에 머물러요.
 - 그래서 많이 퍼뜨려도 과평활이 안 생기고, 퍼뜨리는 데에 추가 파라미터도 없어요.

ENG) b) $\tilde{A} = [0, 0.5, 0.5, 0]; [0.5, 0, 0.5, 0]; [0.3333, 0.3333, 0, 0.3333]; [0, 0, 1, 0]$

ENG) $Z^1 = [0, 0, 0.1667, 0.5]$

ENG) c) $Z^2 = [0.0417, 0.0417, 0.0833, 0.5833]$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.7$, $\gamma_1 = 0.3$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 0 \\ -1 \\ -2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - APPNP fixes the coefficients to alpha times (1-alpha) to the power k, which are always positive and decreasing.
 - GPR-GNN learns the weights, and they are allowed to be negative.
 - A negative weight subtracts that hop, so the model can act as a high-pass filter on heterophilic graphs.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - APPNP 는 계수를 알파 곱하기 (1-알파)의 k제곱으로 못 박아요. 늘 양수이고 줄어들어요.
 - GPR-GNN 은 그 무게를 학습하고, 음수도 될 수 있어요.
 - 음수 무게는 그 걸음을 빼요. 그래서 이질 그래프에서 고주파 필터처럼 동작할 수 있어요.

ENG) b) $H^1 = [-1.5, -2, 0.5, 0.6667]$, $H^2 = [0.5833, 0.6667, -0.4167, -1]$

ENG) c) $Z = [1.5333, -0.7333, -0.4667, -1]$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다.

본 문항에서 가중치 행렬은 모두 1 로 둔다.

a) 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.

b) $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.

c) $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 3 \\ 4 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Theorem 1 says that a vanilla GCN cannot represent the two-hop Delta Operator, even with infinitely many layers.
 - Stacking GCN layers collapses to $\hat{A}$ to the power l times W , so the intermediate hops are never kept separately.
 - MixHop computes each power separately and concatenates them, so a later layer can subtract one from another.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 정리 1 은 보통 GCN 이 두 걸음 델타 연산자를 표현할 수 없다고 말해요. 층을 무한히 쌓아도요.
 - GCN 층을 쌓으면 A 에 1제곱 곱하기 W 꼴로 뭉쳐져서, 중간 걸음들이 따로 남지 않아요.
 - MixHop 은 거듭제곱마다 따로 구해서 나란히 붙여요. 그래서 뒤 층이 하나에서 다른 하나를 뺄 수 있어요.

ENG) b) $A^0 H = [2, 3, 4, -1]$, $A^1 H = [1, 0.5, -1, 3]$, $A^2 H = [1.75, 2, 3, 0.1667]$

ENG) c) $H^1 = \text{concatenation of the three blocks: } [2, 3, 4, 0] \parallel [1, 0.5, 0, 3] \parallel [1.75, 2, 3, 0.1667]$

KOR) c) H1 = 세 조각을 이어 붙여요: [2, 3, 4, 0] | [1, 0.5, 0, 3] | [1.75, 2, 3, 0.1667]

ENG) Delta = [-0.75, -1.5, -3, 2.8333]

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are

PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} 0 & 4 \\ 1 & 3 \\ 1 & -2 \\ -2 & 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Node-wise over-smoothing means the features of connected nodes become too similar.
 - Feature-wise over-smoothing means all node features become indistinguishable across the whole graph.
 - PairNorm keeps the total pairwise squared distance between node representations constant across layers.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 과평활은 이어진 노드들의 특징이 너무 비슷해지는 것이에요.
 - 특징 단위 과평활은 그래프 전체에서 모든 노드 특징이 구별이 안 되게 되는 것이에요.
 - PairNorm 은 층을 지나도 노드 사이 거리 제곱의 합을 일정하게 지켜요.

ENG) b) Mean = [0, 1.5], centered = [0, 2.5]; [1, 1.5]; [1, -3.5]; [-2, -0.5]

KOR) b) 평균 = [0, 1.5], 중심을 뺀 것 = [0, 2.5]; [1, 1.5]; [1, -3.5]; [-2, -0.5]

ENG) c) Scaling denominator = 2.5981, $x = [0, 0.9623]; [0.3849, 0.5774]; [0.3849, -1.3472]; [-0.7698, -0.1925]$

KOR) c) 분모 = 2.5981, $x = [0, 0.9623]; [0.3849, 0.5774]; [0.3849, -1.3472]; [-0.7698, -0.1925]$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (C, D) and (A, C) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -2 \\ 2 \\ 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - DropEdge targets over-fitting and over-smoothing.
 - A different random subgraph is used at every epoch, which works as data augmentation on the graph.
 - Dropout zeroes entries of the feature tensor, while DropEdge removes edges of the adjacency matrix.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - DropEdge 는 과적합과 과평활을 노려요.
 - 판마다 다른 부분 그래프를 써요. 그래프에 자료를 늘리는 효과가 나요.
 - Dropout 은 특징 값을 0 으로 꺼요. DropEdge 는 인접행렬의 선을 지워요.

ENG) b) Expected number of surviving edges = 4, $H_1 = [0.6667, 1.3333, 0, 0]$

KOR) b) 남는 선 수의 기댓값 = 4, $H_1 = [0.6667, 1.3333, 0, 0]$

ENG) c) $H_1 = [0, 1.3333, 0, 0]$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

풀이

ENG)

- Write these three sentences.
 - BFS explores the immediate neighbourhood first, so the embedding captures the structural role of a node.
 - DFS moves far away from the source, so the embedding captures community membership.
 - A small q makes $1/q$ large, so the walk moves outward and behaves like DFS.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - BFS 는 바로 옆 이웃부터 훑어요. 그래서 임베딩이 노드의 구조적 역할을 담아요.
 - DFS 는 출발점에서 멀리 가요. 그래서 임베딩이 어느 동네 소속인지를 담아요.
 - q 가 작으면 $1/q$ 가 커져서 걸음이 바깥으로 나가요. DFS 처럼 움직여요.

ENG) b) $\pi(B \rightarrow A) = 0.5$, $\pi(B \rightarrow C) = 2$, $\pi(B \rightarrow E) = 1$

ENG) c) $P(A) = 0.1429$, $P(C) = 0.5714$, $P(E) = 0.2857$

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = 1, u'_C = 0.5, u'_D = -1.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate $p_2(A|C)$, $p_2(B|C)$, $p_2(C|C)$ and $p_2(D|C)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

풀이

ENG)

- Write these three sentences.
 - First-order proximity is the similarity between two nodes that are directly connected by an edge.
 - Second-order proximity is the similarity between two nodes that share many neighbours, even without an edge.
 - So LINE gives each node two vectors: its own embedding and its context embedding.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 1차 근접도는 선으로 직접 이어진 두 노드 사이의 비슷함이에요.
 - 2차 근접도는 이웃을 많이 공유하는 두 노드의 비슷함이에요. 선이 없어도 돼요.
 - 그래서 LINE 은 노드마다 벡터를 두 개 뒹요. 자기 벡터와 맥락 벡터예요.

ENG) b) $p_2(A|C) = 0.2963$, $p_2(B|C) = 0.1412$, $p_2(C|C) = 0.1806$, $p_2(D|C) = 0.3819$

ENG)**11. (GCN)** Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ -2 \\ 2 \\ -2 \\ 4 \end{bmatrix}$$

풀이**ENG)**

- Write these three sentences.
 - In one layer each node aggregates the features of its direct neighbours and takes the average.
 - The row-normalized matrix $\tilde{A}$ equals $D^{-1}A$, which performs this averaging.
 - After k layers a node has received information from all nodes within k hops.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 한 층에서 노드는 바로 옆 이웃의 특징을 모아 평균을 내요.
 - 행 정규화 행렬 $\tilde{A}$ 는 D 의 역행렬 곱하기 A 이고, 그것이 평균을 내 줘요.
 - k 개 층을 지나면 노드는 k 걸음 안의 모든 노드 정보를 받아요.

ENG) b) $\tilde{A} = [0, 0.5, 0.5, 0, 0]; [0.5, 0, 0, 0, 0.5]; [0.3333, 0, 0, 0.3333, 0.3333]; [0, 0, 0.5, 0, 0.5]; [0, 0.3333, 0.3333, 0.3333, 0]$

ENG) c) $H_1 = [0, 1.5, 0.3333, 3, 0]$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE learns an aggregator function instead of a fixed embedding for each node.
 - It samples a fixed number of neighbours, so it can be trained in mini-batches on very large graphs.
 - A GCN is transductive, but GraphSAGE is inductive, so it can embed a node that was never seen in training.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE는 노드마다 고정된 벡터를 배우는 대신 모으는 함수를 배워요.
 - 이웃을 정해진 개수만 뽑아요. 그래서 아주 큰 그래프에서도 미니배치로 학습할 수 있어요.
 - GCN은 전이적이고 GraphSAGE는 귀납적이에요. 그래서 학습 때 못 본 노드도 벡터를 만들 수 있어요.

ENG) b) $h(A) = [0, 0]$, $h(B) = [3, 0]$, $h(C) = [0, 0.5]$, $h(D) = [0, 0]$, $h(E) = [0, 0.5]$

ENG) c) $hG = [0.6, 0.2]$

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Mini-batch training updates the parameters using a small subset of the data at a time.
 - A large graph does not fit in memory, so ClusterGCN partitions the graph into densely connected clusters.
 - A good partition keeps most edges inside a batch, so little information is lost at the boundary.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 미니배치 학습은 한 번에 자료의 일부만 써서 파라미터를 고쳐요.
 - 큰 그래프는 메모리에 안 들어가요. 그래서 ClusterGCN 은 안쪽이 촘촘한 덩어리로 나뉘요.
 - 잘 나누면 선 대부분이 배치 안에 남아서 경계에서 잃는 정보가 적어요.

ENG) b) $h(A) = [3, 4]$, $h(B) = [4, 3]$, $h(C) = [0, 0]$, $h(D) = [2, 0]$, $h(E) = [1, 0]$, $h(F) = [0, 1]$

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE and FastGCN sample while building the layers, so sampling is repeated at every layer.
 - GraphSAINT samples a subgraph first and then builds the full GNN on that subgraph.
 - So the cost does not grow with depth, and normalization coefficients correct the sampling bias.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE와 FastGCN은 층을 쌓으면서 뽑아요. 그래서 층마다 뽑기를 되풀이해요.
 - GraphSAINT는 부분 그래프를 먼저 뽑고 그 위에 GNN을 통째로 올려요.
 - 그래서 깊어져도 비용이 안 늘고, 정규화 계수로 뽑기의 치우침을 바로잡아요.

ENG) b) $h(A) = [4, 1.5]$, $h(B) = [4, 3]$, $h(C) = [2, 4]$, $h(D) = [0, 4]$

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 0 \\ -3 \\ -1 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In a deep GCN every node repeatedly averages its neighbours, so all representations become similar. This is over-smoothing.
 - JKNet keeps the representation of every layer and combines them at the end by max, concatenation or an LSTM.
 - The best depth is different for each node, so each node can select the depth that suits it.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 에서는 노드가 이웃 평균을 거듭 내서 표현들이 다 비슷해져요. 이것이 과평활이에요.
 - JKNet 은 모든 층의 표현을 들고 있다가 끝에서 최댓값, 이어 붙이기, LSTM 으로 합쳐요.
 - 알맞은 깊이는 노드마다 달라요. 그래서 노드마다 자기에게 맞는 깊이를 고를 수 있어요.

ENG) b) $\text{Atilde} = [0, 0.3333, 0, 0.3333, 0.3333]; [0.5, 0, 0, 0.5, 0]; [0, 0, 0, 0, 1]; [0.3333, 0.3333, 0, 0, 0.3333]; [0.3333, 0, 0.3333, 0.3333, 0]$

ENG) $H1 = [0, 1, 0, 0.6667, 0]$

ENG) c) $H2 = [0.5556, 1, 0, 0.6667, 0.2222]$

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.2$, $\beta = 0.4$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -3 \\ -1 \\ 1 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - The two components are the initial residual connection and the identity mapping.
 - The initial residual connection adds a fraction alpha of the input H zero back at every layer.
 - The identity mapping keeps the weight matrix close to the identity, so a deep model is not destroyed.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 두 장치는 초기 잔차 연결과 항등 사상이에요.
 - 초기 잔차 연결은 층마다 입력 $H^{(0)}$ 의 일부를 알파만큼 다시 더해요.
 - 항등 사상은 가중치 행렬을 단위행렬에 가깝게 뒹요. 그래서 깊어져도 신호가 안 망가져요.

ENG) b) $A_{ilde} = [0, 0, 0, 0.5, 0.5]; [0, 0, 0.5, 0, 0.5]; [0, 0.5, 0, 0.5, 0]; [0.3333, 0, 0.3333, 0, 0.3333]; [0.3333, 0.3333, 0, 0.3333, 0]$

ENG) c) $H_1 = [0, 0, 0, 0, 0]$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 0 \\ 3 \\ 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Deep GCNs suffer from vanishing gradients and over-smoothing, so adding layers makes the model worse.
 - A residual connection passes the input forward unchanged, so each layer only has to learn the change.
 - If no change is useful the layer can output zero, and gradients also flow back through the skip path.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 은 기울기 소실과 과평활을 겪어요. 그래서 층을 더하면 오히려 나빠져요.
 - 잔차 연결은 입력을 그대로 앞으로 보내요. 그래서 층은 바뀌는 양만 배우면 돼요.
 - 바꿀 게 없으면 층은 0 을 내보내면 돼요. 기울기도 그 지름길로 되돌아 흘러요.

ENG) b) $H_1 = [-1.5, 0.6667, 3.5, 1.3333]$

ENG) $H_2 = [-0.5, 1.7778, 4.5, 2.2222]$

ENG) c) Plain GCN without residual: $H_1 = [0.5, 0.6667, 0.5, 0.3333]$ (the node's own value and negatives disappear)

KOR) c) 잔차 없는 GCN 의 $H_1 = [0.5, 0.6667, 0.5, 0.3333]$ (잔차가 없으면 자기 값과 음수가 사라져요)

3회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Relational classification assumes homophily: connected nodes tend to share the same label.
 - It repeatedly sets each unlabelled node to the weighted average of its neighbours' class probabilities.
 - Its limitation is that it uses only the graph structure and ignores node features.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 관계형 분류는 동질성을 가정해요. 이어진 노드끼리는 같은 이름표를 가지는 경향이 있다는 뜻이에요.
 - 이름표 없는 노드를 이웃들의 확률의 가중 평균으로 거듭 바뀌어요.
 - 한계는 그래프 구조만 쓰고 노드의 특징은 무시한다는 것이에요.

ENG) b) $P(Y_1) = 1, P(Y_2) = 0.5, P(Y_3) = 0.5, P(Y_4) = 0.75, P(Y_5) = 0$

ENG) c) $P(Y1) = 1$, $P(Y2) = 0.5833$, $P(Y3) = 0.5$, $P(Y4) = 0.75$, $P(Y5) = 0$

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{B, C\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 1 \\ 0 \\ -2 \\ -1 \\ 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In node-wise sampling, each node samples its own neighbours, so the cost grows exponentially with depth.
 - FastGCN samples a fixed-size set of nodes once per layer, shared by all nodes in that layer.
 - Therefore the cost grows only linearly with depth instead of exponentially.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 뽑기는 노드마다 제 이웃을 뽑아서, 층이 깊어질수록 비용이 지수로 커져요.
 - FastGCN 은 층마다 정해진 개수를 한 번만 뽑고, 그 층의 모든 노드가 같이 써요.
 - 그래서 비용이 지수가 아니라 층 수에 비례해서만 늘어요.

ENG) b) $q(A) = 0.0444$, $q(B) = 0.4889$, $q(C) = 0.0889$, $q(D) = 0.1889$, $q(E) = 0.1889$

ENG) c) $h^{(1)}(A) = 0$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = C$.
- Calculate $E_{p(u_j | C)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(C)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -1 \\ -1 \\ 4 \\ 1 \\ -2 \end{bmatrix}$$

풀이**ENG)**

- Write these three sentences.
 - In FastGCN the sampling distribution is fixed in advance and does not depend on the parent nodes.
 - In ASGCN the proposal distribution is conditioned on the nodes of the upper layer.
 - This makes almost every sampled node useful and reduces the variance of the estimate.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - FastGCN 의 뽑기 확률은 미리 정해져 있고 부모 노드와 상관이 없어요.
 - ASGCN 은 뽑기 확률을 윗층 노드에 맞춰 정해요.
 - 그래서 뽑은 노드가 거의 다 쓸모 있고, 추정값의 흔들림이 줄어요.

ENG) b) $N(C) = 1$, $p(A|C) = 0.3333$, $p(D|C) = 0.3333$, $p(E|C) = 0.3333$

ENG) c) $E = -0.6667$, $h_1(C) = 0$

ENG)

4. (APPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.5$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - At every propagation step the walk returns to the root node with probability alpha. This is the teleport mechanism.
 - Because a fixed fraction of the mass is pulled back at every step, the distribution stays local.
 - So we can use many propagation steps without over-smoothing, and propagation has no extra parameters.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 퍼뜨리는 걸음마다 확률 알파로 출발 노드로 되돌아가요. 이것이 순간이동 장치예요.
 - 매 걸음 일정 비율이 되돌아오니까 분포가 출발점 근처에 머물러요.
 - 그래서 많이 퍼뜨려도 과평활이 안 생기고, 퍼뜨리는 데에 추가 파라미터도 없어요.

ENG) b) $\tilde{A} = [0, 0, 0.5, 0.5]; [0, 0, 0.5, 0.5]; [0.5, 0.5, 0, 0]; [0.5, 0.5, 0, 0]$

ENG) $Z^1 = [0.25, 0.25, 0, 0.5]$

ENG) c) $Z^2 = [0.125, 0.125, 0.125, 0.625]$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.5$, $\gamma_1 = 0.2$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ -1 \\ 4 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - APPNP fixes the coefficients to alpha times (1-alpha) to the power k, which are always positive and decreasing.
 - GPR-GNN learns the weights, and they are allowed to be negative.
 - A negative weight subtracts that hop, so the model can act as a high-pass filter on heterophilic graphs.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - APPNP 는 계수를 알파 곱하기 (1-알파)의 k제곱으로 못 박아요. 늘 양수이고 줄어들어요.
 - GPR-GNN 은 그 무게를 학습하고, 음수도 될 수 있어요.
 - 음수 무게는 그 걸음을 빼요. 그래서 이질 그래프에서 고주파 필터처럼 동작할 수 있어요.

ENG) b) $H_1 = [1, 1.5, 1, 1.5]$, $H_2 = [1.5, 1, 1.5, 1]$

ENG) c) $Z = [1.9, -0.9, -0.6, 2.1]$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다. 본 문항에서 가중치 행렬은 모두 1로 둔다.

- 두 걸음 델타 연산자에 관한 MixHop의 정리 1을 서술하고, 보통의 GCN이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.
- $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.
- $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ -2 \\ 1 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Theorem 1 says that a vanilla GCN cannot represent the two-hop Delta Operator, even with infinitely many layers.
 - Stacking GCN layers collapses to $\hat{A}$ to the power l times W , so the intermediate hops are never kept separately.
 - MixHop computes each power separately and concatenates them, so a later layer can subtract one from another.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 정리 1은 보통 GCN이 두 걸음 델타 연산자를 표현할 수 없다고 말해요. 층을 무한히 쌓아도요.
 - GCN 층을 쌓으면 A 에 1제곱 곱하기 W 꼴로 뭉쳐져서, 중간 걸음들이 따로 남지 않아요.
 - MixHop은 거듭제곱마다 따로 구해서 나란히 붙여요. 그래서 뒤 층이 하나에서 다른 하나를 뺄 수 있어요.

ENG) b) $A^0 H = [2, -2, 1, -1]$, $A^1 H = [0, -1, 0.5, 0.3333]$, $A^2 H = [0.4167, 0.3333, 0.1667, -0.1667]$

ENG) c) $H^1 = \text{concatenation of the three blocks: } [2, 0, 1, 0] \parallel [0, 0, 0.5, 0.3333] \parallel [0.4167, 0.3333, 0.1667, 0]$

KOR) c) H1 = 세 조각을 이어 붙여요: $[2, 0, 1, 0] \mid [0, 0, 0.5, 0.3333] \mid [0.4167, 0.3333, 0.1667, 0]$

ENG) $\Delta = [-0.4167, -0.3333, 0.3333, 0.3333]$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are

PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} 4 & 0 \\ 1 & 3 \\ 1 & -1 \\ -1 & 4 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Node-wise over-smoothing means the features of connected nodes become too similar.
 - Feature-wise over-smoothing means all node features become indistinguishable across the whole graph.
 - PairNorm keeps the total pairwise squared distance between node representations constant across layers.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 과평활은 이어진 노드들의 특징이 너무 비슷해지는 것이에요.
 - 특징 단위 과평활은 그래프 전체에서 모든 노드 특징이 구별이 안 되게 되는 것이에요.
 - PairNorm 은 층을 지나도 노드 사이 거리 제곱의 합을 일정하게 지켜요.

ENG) b) Mean = [1.25, 1.5], centered = [2.75, -1.5]; [-0.25, 1.5]; [-0.25, -2.5]; [-2.25, 2.5]

KOR) b) 평균 = [1.25, 1.5], 중심을 뺀 것 = [2.75, -1.5]; [-0.25, 1.5]; [-0.25, -2.5]; [-2.25, 2.5]

ENG) c) Scaling denominator = 2.7272, $x = [1.0084, -0.55]; [-0.0917, 0.55]; [-0.0917, -0.9167]; [-0.825, 0.9167]$

KOR) c) 분모 = 2.7272, $x = [1.0084, -0.55]; [-0.0917, 0.55]; [-0.0917, -0.9167]; [-0.825, 0.9167]$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (A, C) and (B, D) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ -3 \\ 4 \\ 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - DropEdge targets over-fitting and over-smoothing.
 - A different random subgraph is used at every epoch, which works as data augmentation on the graph.
 - Dropout zeroes entries of the feature tensor, while DropEdge removes edges of the adjacency matrix.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - DropEdge 는 과적합과 과평활을 노려요.
 - 판마다 다른 부분 그래프를 써요. 그래프에 자료를 늘리는 효과가 나요.
 - Dropout 은 특징 값을 0 으로 꺼요. DropEdge 는 인접행렬의 선을 지워요.

ENG) b) Expected number of surviving edges = 4, $H_1 = [1.3333, 2.3333, 0, 0.3333]$

KOR) b) 남는 선 수의 기댓값 = 4, $H_1 = [1.3333, 2.3333, 0, 0.3333]$

ENG) c) $H_1 = [0, 2, 0, 2]$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

풀이

ENG)

- Write these three sentences.
 - BFS explores the immediate neighbourhood first, so the embedding captures the structural role of a node.
 - DFS moves far away from the source, so the embedding captures community membership.
 - A small q makes $1/q$ large, so the walk moves outward and behaves like DFS.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - BFS 는 바로 옆 이웃부터 훑어요. 그래서 임베딩이 노드의 구조적 역할을 담아요.
 - DFS 는 출발점에서 멀리 가요. 그래서 임베딩이 어느 동네 소속인지를 담아요.
 - q 가 작으면 $1/q$ 가 커져서 걸음이 바깥으로 나가요. DFS 처럼 움직여요.

ENG) b) $\pi(B \rightarrow A) = 0.5$, $\pi(B \rightarrow C) = 2$, $\pi(B \rightarrow D) = 1$

ENG) c) $P(A) = 0.1429$, $P(C) = 0.5714$, $P(D) = 0.2857$

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = 0.5, u'_C = 1, u'_D = -1.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate $p_2(A|B)$, $p_2(B|B)$, $p_2(C|B)$ and $p_2(D|B)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

풀이

ENG)

- Write these three sentences.
 - First-order proximity is the similarity between two nodes that are directly connected by an edge.
 - Second-order proximity is the similarity between two nodes that share many neighbours, even without an edge.
 - So LINE gives each node two vectors: its own embedding and its context embedding.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 1차 근접도는 선으로 직접 이어진 두 노드 사이의 비슷함이에요.
 - 2차 근접도는 이웃을 많이 공유하는 두 노드의 비슷함이에요. 선이 없어도 돼요.
 - 그래서 LINE 은 노드마다 벡터를 두 개 뒹요. 자기 벡터와 맥락 벡터예요.

ENG) b) $p_2(A|B) = 0.1806$, $p_2(B|B) = 0.2963$, $p_2(C|B) = 0.3819$, $p_2(D|B) = 0.1412$

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -2 \\ -1 \\ 4 \\ 4 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In one layer each node aggregates the features of its direct neighbours and takes the average.
 - The row-normalized matrix $\tilde{A}$ equals $D^{-1}A$, which performs this averaging.
 - After k layers a node has received information from all nodes within k hops.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 한 층에서 노드는 바로 옆 이웃의 특징을 모아 평균을 내요.
 - 행 정규화 행렬 $\tilde{A}$ 는 D 의 역행렬 곱하기 A 이고, 그것이 평균을 내 줘요.
 - k 개 층을 지나면 노드는 k 걸음 안의 모든 노드 정보를 받아요.

ENG) b) $\tilde{A} = [0, 0, 0.5, 0, 0.5]; [0, 0, 0.3333, 0.3333, 0.3333]; [0.3333, 0.3333, 0, 0, 0.3333]; [0, 1, 0, 0, 0]; [0.3333, 0.3333, 0.3333, 0, 0]$

ENG) c) $H_1 = [1.5, 2.3333, 1, 0, 0]$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE learns an aggregator function instead of a fixed embedding for each node.
 - It samples a fixed number of neighbours, so it can be trained in mini-batches on very large graphs.
 - A GCN is transductive, but GraphSAGE is inductive, so it can embed a node that was never seen in training.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE는 노드마다 고정된 벡터를 배우는 대신 모으는 함수를 배워요.
 - 이웃을 정해진 개수만 뽑아요. 그래서 아주 큰 그래프에서도 미니배치로 학습할 수 있어요.
 - GCN은 전이적이고 GraphSAGE는 귀납적이에요. 그래서 학습 때 못 본 노드도 벡터를 만들 수 있어요.

ENG) b) $h(A) = [0, 1]$, $h(B) = [3, 0.6667]$, $h(C) = [4, 0.5]$, $h(D) = [0, 2.3333]$, $h(E) = [2, 0]$

ENG) c) $hG = [1.8, 0.9]$

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Mini-batch training updates the parameters using a small subset of the data at a time.
 - A large graph does not fit in memory, so ClusterGCN partitions the graph into densely connected clusters.
 - A good partition keeps most edges inside a batch, so little information is lost at the boundary.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 미니배치 학습은 한 번에 자료의 일부만 써서 파라미터를 고쳐요.
 - 큰 그래프는 메모리에 안 들어가요. 그래서 ClusterGCN은 안쪽이 촘촘한 덩어리로 나뉘요.
 - 잘 나누면 선 대부분이 배치 안에 남아서 경계에서 잃는 정보가 적어요.

ENG) b) $h(A) = [0, 0]$, $h(B) = [3, 1]$, $h(C) = [1, 3]$, $h(D) = [2, 4]$, $h(E) = [4, 2]$, $h(F) = [2, 4]$

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE and FastGCN sample while building the layers, so sampling is repeated at every layer.
 - GraphSAINT samples a subgraph first and then builds the full GNN on that subgraph.
 - So the cost does not grow with depth, and normalization coefficients correct the sampling bias.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE와 FastGCN은 층을 쌓으면서 뽑아요. 그래서 층마다 뽑기를 되풀이해요.
 - GraphSAINT는 부분 그래프를 먼저 뽑고 그 위에 GNN을 통째로 올려요.
 - 그래서 깊어져도 비용이 안 늘고, 정규화 계수로 뽑기의 치우침을 바로잡아요.

ENG) b) $h(A) = [1, 0]$, $h(B) = [0, 0]$, $h(C) = [0, 0]$, $h(D) = [2, 0]$

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -3 \\ -3 \\ -3 \\ 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In a deep GCN every node repeatedly averages its neighbours, so all representations become similar. This is over-smoothing.
 - JKNet keeps the representation of every layer and combines them at the end by max, concatenation or an LSTM.
 - The best depth is different for each node, so each node can select the depth that suits it.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 에서는 노드가 이웃 평균을 거듭 내서 표현들이 다 비슷해져요. 이것이 과평활이에요.
 - JKNet 은 모든 층의 표현을 들고 있다가 끝에서 최댓값, 이어 붙이기, LSTM 으로 합쳐요.
 - 알맞은 깊이는 노드마다 달라요. 그래서 노드마다 자기에게 맞는 깊이를 고를 수 있어요.

ENG) b) $A_{tilde} = [0, 0.25, 0.25, 0.25, 0.25]; [0.3333, 0, 0, 0.3333, 0.3333]; [1, 0, 0, 0, 0]; [0.5, 0.5, 0, 0, 0]; [0.5, 0.5, 0, 0, 0]$

ENG) H1 = [0, 1.3333, 4, 0.5, 0.5]

ENG) c) H2 = [1.5833, 1.3333, 4, 0.6667, 0.6667]

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.2$, $\beta = 0.4$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha)\tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 3 \\ 3 \\ 0 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - The two components are the initial residual connection and the identity mapping.
 - The initial residual connection adds a fraction alpha of the input H zero back at every layer.
 - The identity mapping keeps the weight matrix close to the identity, so a deep model is not destroyed.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 두 장치는 초기 잔차 연결과 항등 사상이에요.
 - 초기 잔차 연결은 층마다 입력 $H^{(0)}$ 의 일부를 알파만큼 다시 더해요.
 - 항등 사상은 가중치 행렬을 단위행렬에 가깝게 뒹요. 그래서 깊어져도 신호가 안 망가져요.

ENG) b) $\tilde{A} = [0, 0.5, 0.5, 0, 0]; [0.3333, 0, 0, 0.3333, 0.3333]; [0.3333, 0, 0, 0.3333, 0.3333]; [0, 0.5, 0.5, 0, 0]; [0, 0.5, 0.5, 0, 0]$

ENG) c) $H^1 = [1.08, 0, 0, 1.44, 1.32]$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows: Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 1 \\ 2 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Deep GCNs suffer from vanishing gradients and over-smoothing, so adding layers makes the model worse.
 - A residual connection passes the input forward unchanged, so each layer only has to learn the change.
 - If no change is useful the layer can output zero, and gradients also flow back through the skip path.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 은 기울기 소실과 과평활을 겪어요. 그래서 층을 더하면 오히려 나빠져요.
 - 잔차 연결은 입력을 그대로 앞으로 보내요. 그래서 층은 바뀌는 양만 배우면 돼요.
 - 바꿀 게 없으면 층은 0 을 내보내면 돼요. 기울기도 그 지름길로 되돌아 흘러요.

ENG) b) $H_1 = [-1.5, 1, 2, 1.5]$

ENG) $H_2 = [0, 1.6667, 2.3333, 3]$

ENG) c) Plain GCN without residual: $H_1 = [1.5, 0, 0, 1.5]$ (the node's own value and negatives disappear)

KOR) c) 잔차 없는 GCN 의 $H_1 = [1.5, 0, 0, 1.5]$ (잔차가 없으면 자기 값과 음수가 사라져요)

4회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Relational classification assumes homophily: connected nodes tend to share the same label.
 - It repeatedly sets each unlabelled node to the weighted average of its neighbours' class probabilities.
 - Its limitation is that it uses only the graph structure and ignores node features.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 관계형 분류는 동질성을 가정해요. 이어진 노드끼리는 같은 이름표를 가지는 경향이 있다는 뜻이에요.
 - 이름표 없는 노드를 이웃들의 확률의 가중 평균으로 거듭 바뀌요.
 - 한계는 그래프 구조만 쓰고 노드의 특징은 무시한다는 것이에요.

ENG) b) $P(Y_1) = 1, P(Y_2) = 0.25, P(Y_3) = 0.3333, P(Y_4) = 0.75, P(Y_5) = 0$

ENG) c) $P(Y1) = 1, P(Y2) = 0.1667, P(Y3) = 0.3333, P(Y4) = 0.6667, P(Y5) = 0$

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left(\frac{1}{t_l} \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{D, E\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 3 \\ 3 \\ 2 \\ 0 \\ 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In node-wise sampling, each node samples its own neighbours, so the cost grows exponentially with depth.
 - FastGCN samples a fixed-size set of nodes once per layer, shared by all nodes in that layer.
 - Therefore the cost grows only linearly with depth instead of exponentially.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 뽑기는 노드마다 제 이웃을 뽑아서, 층이 깊어질수록 비용이 지수로 커져요.
 - FastGCN 은 층마다 정해진 개수를 한 번만 뽑고, 그 층의 모든 노드가 같이 써요.
 - 그래서 비용이 지수가 아니라 층 수에 비례해서만 늘어요.

ENG) b) $q(A) = 0.2821$, $q(B) = 0.1667$, $q(C) = 0.1667$, $q(D) = 0.2821$, $q(E) = 0.1026$

ENG) c) $h^{(1)}(A) = 0.3333$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = B$.
- Calculate $E_{p(u_j | B)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(B)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 0 \\ -1 \\ 2 \\ 4 \\ 2 \end{bmatrix}$$

풀이**ENG)**

- Write these three sentences.
 - In FastGCN the sampling distribution is fixed in advance and does not depend on the parent nodes.
 - In ASGCN the proposal distribution is conditioned on the nodes of the upper layer.
 - This makes almost every sampled node useful and reduces the variance of the estimate.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - FastGCN 의 뽑기 확률은 미리 정해져 있고 부모 노드와 상관이 없어요.
 - ASGCN 은 뽑기 확률을 윗층 노드에 맞춰 정해요.
 - 그래서 뽑은 노드가 거의 다 쓸모 있고, 추정값의 흔들림이 줄어요.

ENG) b) $N(B) = 1$, $p(A|B) = 0.3333$, $p(C|B) = 0.3333$, $p(D|B) = 0.3333$

ENG) c) $E = 2$, $h_1(B) = 2$

ENG)

4. (APPP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.2$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - At every propagation step the walk returns to the root node with probability alpha. This is the teleport mechanism.
 - Because a fixed fraction of the mass is pulled back at every step, the distribution stays local.
 - So we can use many propagation steps without over-smoothing, and propagation has no extra parameters.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 퍼뜨리는 걸음마다 확률 알파로 출발 노드로 되돌아가요. 이것이 순간이동 장치예요.
 - 매 걸음 일정 비율이 되돌아오니까 분포가 출발점 근처에 머물러요.
 - 그래서 많이 퍼뜨려도 과평활이 안 생기고, 퍼뜨리는 데에 추가 파라미터도 없어요.

ENG) b) $\tilde{A} = [0, 0.3333, 0.3333, 0.3333]; [1, 0, 0, 0]; [0.5, 0, 0, 0.5]; [0.5, 0, 0.5, 0]$

ENG) $Z^1 = [0.2, 0.8, 0.4, 0.4]$

ENG) c) $Z^2 = [0.6267, 0.16, 0.24, 0.24]$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.5$, $\gamma_1 = 0.4$, $\gamma_2 = -0.2$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 3 \\ -2 \\ 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - APPNP fixes the coefficients to alpha times (1-alpha) to the power k, which are always positive and decreasing.
 - GPR-GNN learns the weights, and they are allowed to be negative.
 - A negative weight subtracts that hop, so the model can act as a high-pass filter on heterophilic graphs.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - APPNP 는 계수를 알파 곱하기 (1-알파)의 k제곱으로 못 박아요. 늘 양수이고 줄어들어요.
 - GPR-GNN 은 그 무게를 학습하고, 음수도 될 수 있어요.
 - 음수 무게는 그 걸음을 빼요. 그래서 이질 그래프에서 고주파 필터처럼 동작할 수 있어요.

ENG) b) $H_1 = [0.5, 0, 1, 3]$, $H_2 = [0.5, 1.5, 0.25, 0]$

ENG) c) $Z = [-0.4, 1.2, -0.65, 2.7]$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다. 본 문항에서 가중치 행렬은 모두 1로 둔다.

- 두 걸음 델타 연산자에 관한 MixHop의 정리 1을 서술하고, 보통의 GCN이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.
- $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.
- $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ -2 \\ -2 \\ 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Theorem 1 says that a vanilla GCN cannot represent the two-hop Delta Operator, even with infinitely many layers.
 - Stacking GCN layers collapses to $\hat{A}$ to the power l times W , so the intermediate hops are never kept separately.
 - MixHop computes each power separately and concatenates them, so a later layer can subtract one from another.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 정리 1은 보통 GCN이 두 걸음 델타 연산자를 표현할 수 없다고 말해요. 층을 무한히 쌓아도요.
 - GCN 층을 쌓으면 A 에 1제곱 곱하기 W 꼴로 뭉쳐져서, 중간 걸음들이 따로 남지 않아요.
 - MixHop은 거듭제곱마다 따로 구해서 나란히 붙여요. 그래서 뒤 층이 하나에서 다른 하나를 뺄 수 있어요.

ENG) b) $A^0 H = [-2, -2, -2, 3]$, $A^1 H = [-2, 0.5, 0.5, -2]$, $A^2 H = [0.5, -2, -2, 0.5]$

ENG) c) $H^1 = \text{concatenation of the three blocks: } [0, 0, 0, 3] \parallel [0, 0.5, 0.5, 0] \parallel [0.5, 0, 0, 0.5]$

KOR) c) H1 = 세 조각을 이어 붙여요: $[0, 0, 0, 3] \mid [0, 0.5, 0.5, 0] \mid [0.5, 0, 0, 0.5]$

ENG) $\Delta = [-0.5, 0.5, 0.5, -0.5]$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} -1 & 0 \\ 0 & 0 \\ 4 & 0 \\ -2 & 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Node-wise over-smoothing means the features of connected nodes become too similar.
 - Feature-wise over-smoothing means all node features become indistinguishable across the whole graph.
 - PairNorm keeps the total pairwise squared distance between node representations constant across layers.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 과평활은 이어진 노드들의 특징이 너무 비슷해지는 것이에요.
 - 특징 단위 과평활은 그래프 전체에서 모든 노드 특징이 구별이 안 되게 되는 것이에요.
 - PairNorm 은 층을 지나도 노드 사이 거리 제곱의 합을 일정하게 지켜요.

ENG) b) Mean = [0.25, 0], centered = [-1.25, 0]; [-0.25, 0]; [3.75, 0]; [-2.25, 0]

KOR) b) 평균 = [0.25, 0], 중심을 뺀 것 = [-1.25, 0]; [-0.25, 0]; [3.75, 0]; [-2.25, 0]

ENG) c) Scaling denominator = 2.2776, $x = [-0.5488, 0]; [-0.1098, 0]; [1.6465, 0]; [-0.9879, 0]$

KOR) c) 분모 = 2.2776, $x = [-0.5488, 0]; [-0.1098, 0]; [1.6465, 0]; [-0.9879, 0]$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (A, D) and (A, C) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 0 \\ 3 \\ 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - DropEdge targets over-fitting and over-smoothing.
 - A different random subgraph is used at every epoch, which works as data augmentation on the graph.
 - Dropout zeroes entries of the feature tensor, while DropEdge removes edges of the adjacency matrix.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - DropEdge 는 과적합과 과평활을 노려요.
 - 판마다 다른 부분 그래프를 써요. 그래프에 자료를 늘리는 효과가 나요.
 - Dropout 은 특징 값을 0 으로 꺼요. DropEdge 는 인접행렬의 선을 지워요.

ENG) b) Expected number of surviving edges = 4, $H_1 = [2, 1.6667, 0.6667, 0.6667]$

KOR) b) 남는 선 수의 기댓값 = 4, $H_1 = [2, 1.6667, 0.6667, 0.6667]$

ENG) c) $H_1 = [0, 1.6667, 1.5, 1.5]$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

풀이

ENG)

- Write these three sentences.
 - BFS explores the immediate neighbourhood first, so the embedding captures the structural role of a node.
 - DFS moves far away from the source, so the embedding captures community membership.
 - A small q makes $1/q$ large, so the walk moves outward and behaves like DFS.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - BFS 는 바로 옆 이웃부터 훑어요. 그래서 임베딩이 노드의 구조적 역할을 담아요.
 - DFS 는 출발점에서 멀리 가요. 그래서 임베딩이 어느 동네 소속인지를 담아요.
 - q 가 작으면 $1/q$ 가 커져서 걸음이 바깥으로 나가요. DFS 처럼 움직여요.

ENG) b) $\pi(B \rightarrow A) = 0.5$, $\pi(B \rightarrow C) = 1$, $\pi(B \rightarrow D) = 2$

ENG) c) $P(A) = 0.1429$, $P(C) = 0.2857$, $P(D) = 0.5714$

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = -0.5, u'_B = -1, u'_C = 0.5, u'_D = 1.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate $p_2(A|B)$, $p_2(B|B)$, $p_2(C|B)$ and $p_2(D|B)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

풀이

ENG)

- Write these three sentences.
 - First-order proximity is the similarity between two nodes that are directly connected by an edge.
 - Second-order proximity is the similarity between two nodes that share many neighbours, even without an edge.
 - So LINE gives each node two vectors: its own embedding and its context embedding.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 1차 근접도는 선으로 직접 이어진 두 노드 사이의 비슷함이에요.
 - 2차 근접도는 이웃을 많이 공유하는 두 노드의 비슷함이에요. 선이 없어도 돼요.
 - 그래서 LINE 은 노드마다 벡터를 두 개 뒹요. 자기 벡터와 맥락 벡터예요.

ENG) b) $p_2(A|B) = 0.1806$, $p_2(B|B) = 0.1412$, $p_2(C|B) = 0.2963$, $p_2(D|B) = 0.3819$

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ -3 \\ -2 \\ 2 \\ -2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In one layer each node aggregates the features of its direct neighbours and takes the average.
 - The row-normalized matrix $\tilde{A}$ equals $D^{-1}A$, which performs this averaging.
 - After k layers a node has received information from all nodes within k hops.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 한 층에서 노드는 바로 옆 이웃의 특징을 모아 평균을 내요.
 - 행 정규화 행렬 $\tilde{A}$ 는 D 의 역행렬 곱하기 A 이고, 그것이 평균을 내 줘요.
 - k 개 층을 지나면 노드는 k 걸음 안의 모든 노드 정보를 받아요.

ENG) b) $\tilde{A} = [0, 0.25, 0.25, 0.25, 0.25]; [0.5, 0, 0, 0, 0.5]; [0.5, 0, 0, 0.5, 0]; [0.5, 0, 0.5, 0, 0]; [0.5, 0.5, 0, 0, 0]$

ENG) c) $H_1 = [0, 0, 0.5, 0, 0]$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE learns an aggregator function instead of a fixed embedding for each node.
 - It samples a fixed number of neighbours, so it can be trained in mini-batches on very large graphs.
 - A GCN is transductive, but GraphSAGE is inductive, so it can embed a node that was never seen in training.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE는 노드마다 고정된 벡터를 배우는 대신 모으는 함수를 배워요.
 - 이웃을 정해진 개수만 뽑아요. 그래서 아주 큰 그래프에서도 미니배치로 학습할 수 있어요.
 - GCN은 전이적이고 GraphSAGE는 귀납적이예요. 그래서 학습 때 못 본 노드도 벡터를 만들 수 있어요.

ENG) b) $h(A) = [0, 0.3333]$, $h(B) = [0, 0]$, $h(C) = [0, 0]$, $h(D) = [0, 0.3333]$, $h(E) = [4, 0]$

ENG) c) $hG = [0.8, 0.1333]$

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Mini-batch training updates the parameters using a small subset of the data at a time.
 - A large graph does not fit in memory, so ClusterGCN partitions the graph into densely connected clusters.
 - A good partition keeps most edges inside a batch, so little information is lost at the boundary.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 미니배치 학습은 한 번에 자료의 일부만 써서 파라미터를 고쳐요.
 - 큰 그래프는 메모리에 안 들어가요. 그래서 ClusterGCN 은 안쪽이 촘촘한 덩어리로 나뉘요.
 - 잘 나누면 선 대부분이 배치 안에 남아서 경계에서 잃는 정보가 적어요.

ENG) b) $h(A) = [0, 0]$, $h(B) = [2, 0]$, $h(C) = [0, 2]$, $h(D) = [0, 2]$, $h(E) = [2, 0]$, $h(F) = [0, 0]$

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE and FastGCN sample while building the layers, so sampling is repeated at every layer.
 - GraphSAINT samples a subgraph first and then builds the full GNN on that subgraph.
 - So the cost does not grow with depth, and normalization coefficients correct the sampling bias.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE와 FastGCN은 층을 쌓으면서 뽑아요. 그래서 층마다 뽑기를 되풀이해요.
 - GraphSAINT는 부분 그래프를 먼저 뽑고 그 위에 GNN을 통째로 올려요.
 - 그래서 깊어져도 비용이 안 늘고, 정규화 계수로 뽑기의 치우침을 바로잡아요.

ENG) b) $h(A) = [4, 2]$, $h(B) = [0, 2]$, $h(C) = [1, 2]$, $h(D) = [2, 1]$

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 2 \\ 0 \\ 0 \\ -2 \\ 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In a deep GCN every node repeatedly averages its neighbours, so all representations become similar. This is over-smoothing.
 - JKNet keeps the representation of every layer and combines them at the end by max, concatenation or an LSTM.
 - The best depth is different for each node, so each node can select the depth that suits it.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 에서는 노드가 이웃 평균을 거듭 내서 표현들이 다 비슷해져요. 이것이 과평활이에요.
 - JKNet 은 모든 층의 표현을 들고 있다가 끝에서 최댓값, 이어 붙이기, LSTM 으로 합쳐요.
 - 알맞은 깊이는 노드마다 달라요. 그래서 노드마다 자기에게 맞는 깊이를 고를 수 있어요.

ENG) b) $A_{tilde} = [0, 0.3333, 0, 0.3333, 0.3333]; [0.3333, 0, 0.3333, 0.3333, 0]; [0, 0.5, 0, 0, 0.5]; [0.5, 0.5, 0, 0, 0]; [0.5, 0, 0.5, 0, 0]$

ENG) H1 = [0.3333, 0, 1.5, 1, 1]

ENG) c) H2 = [0.6667, 0.9444, 1.5, 1, 1]

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.5$, $\beta = 0.5$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ 4 \\ -2 \\ 3 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - The two components are the initial residual connection and the identity mapping.
 - The initial residual connection adds a fraction alpha of the input H zero back at every layer.
 - The identity mapping keeps the weight matrix close to the identity, so a deep model is not destroyed.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 두 장치는 초기 잔차 연결과 항등 사상이에요.
 - 초기 잔차 연결은 층마다 입력 $H^{(0)}$ 의 일부를 알파만큼 다시 더해요.
 - 항등 사상은 가중치 행렬을 단위행렬에 가깝게 뒹요. 그래서 깊어져도 신호가 안 망가져요.

ENG) b) $A_{ilde} = [0, 0.5, 0, 0.5, 0]; [0.3333, 0, 0.3333, 0.3333, 0]; [0, 0.5, 0, 0, 0.5]; [0.3333, 0.3333, 0, 0, 0.3333]; [0, 0, 0.5, 0.5, 0]$

ENG) c) $H_1 = [1.625, 1.3333, 0, 1.25, 0]$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 4 \\ -2 \\ 0 \\ -2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Deep GCNs suffer from vanishing gradients and over-smoothing, so adding layers makes the model worse.
 - A residual connection passes the input forward unchanged, so each layer only has to learn the change.
 - If no change is useful the layer can output zero, and gradients also flow back through the skip path.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 은 기울기 소실과 과평활을 겪어요. 그래서 층을 더하면 오히려 나빠져요.
 - 잔차 연결은 입력을 그대로 앞으로 보내요. 그래서 층은 바뀌는 양만 배우면 돼요.
 - 바꿀 게 없으면 층은 0 을 내보내면 돼요. 기울기도 그 지름길로 되돌아 흘러요.

ENG) b) $H_1 = [4, -1.3333, 0, -1.3333]$

ENG) $H_2 = [4, -0.4444, 0, -0.4444]$

ENG) c) Plain GCN without residual: $H_1 = [0, 0.6667, 0, 0.6667]$ (the node's own value and negatives disappear)

KOR) c) 잔차 없는 GCN 의 $H_1 = [0, 0.6667, 0, 0.6667]$ (잔차가 없으면 자기 값과 음수가 사라져요)

5회차

ENG)

1. (Relational Classification) Consider an undirected graph G of five nodes given in the following figure. Nodes 1 and 5 are labelled ($P(Y_1) = 1, P(Y_5) = 0$) and the others are unlabelled and initialized to 0.5. The relational classifier updates every unlabelled node as:

$$P(Y_v = c) = (\sum_{(v,u) \in E} A_{v,u} P(Y_u = c)) / (\sum_{(v,u) \in E} A_{v,u})$$

- Explain the key assumption behind relational classification, and state one limitation.
- Calculate $P(Y_v)$ for every unlabelled node after the 1st iteration.
- Calculate $P(Y_v)$ after the 2nd iteration, using the previous iteration's values only.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 노드 1과 5에는 이름표가 주어져 있으며($P(Y_1)=1, P(Y_5)=0$), 나머지 노드는 이름표가 없고 0.5로 초기화한다.

관계형 분류기는 이름표가 없는 각 노드를 이웃 노드들의 부류 확률에 대한 가중 평균으로 갱신한다. 분모는 해당 노드에 연결된 간선 가중치의 합이다.

- 관계형 분류가 전제하는 핵심 가정과 그 한계 하나를 서술하시오.
- 1차 반복 후 이름표가 없는 각 노드의 $P(Y_v)$ 를 계산하시오.
- 2차 반복 후의 $P(Y_v)$ 를 계산하시오. 단, 직전 반복의 값만 사용한다.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Relational classification assumes homophily: connected nodes tend to share the same label.
 - It repeatedly sets each unlabelled node to the weighted average of its neighbours' class probabilities.
 - Its limitation is that it uses only the graph structure and ignores node features.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 관계형 분류는 동질성을 가정해요. 이어진 노드끼리는 같은 이름표를 가지는 경향이 있다는 뜻이에요.
 - 이름표 없는 노드를 이웃들의 확률의 가중 평균으로 거듭 바뀌어요.
 - 한계는 그래프 구조만 쓰고 노드의 특징은 무시한다는 것이에요.

ENG) b) $P(Y_1) = 1, P(Y_2) = 0.6667, P(Y_3) = 0.25, P(Y_4) = 0.75, P(Y_5) = 0$

ENG) c) $P(Y1) = 1$, $P(Y2) = 0.6667$, $P(Y3) = 0.3333$, $P(Y4) = 0.8333$, $P(Y5) = 0$

ENG)

2. (FastGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. FastGCN replaces the full neighbourhood sum of a GCN layer by a layer-wise Monte-Carlo estimate:

$$h^{(l+1)}(v) = \sigma \left((1/t_l) \sum_{j=1}^{t_l} \tilde{A}(v, u_j) h^{(l)}(u_j) \right)$$

where $\tilde{A} = D^{-1}A$ and the t_l nodes are drawn once per layer from $q(u) \propto \|\tilde{A}(:, u)\|^2$, with $\text{ReLU}(x) = \max(0, x)$.

- How does layer-wise sampling differ from the node-wise sampling of GraphSAGE?
- Calculate the importance distribution $q(u)$ over the five nodes.
- Suppose the sampled set is $\{B, E\}$ ($t_l = 2$). Calculate the estimate of $h^{(1)}(A)$.

KOR)

인접행렬 A 와 노드 특징 벡터 $h^{(0)}$ 가 주어진 무방향 그래프 G 를 고려한다.

FastGCN 은 GCN 한 층의 전체 이웃 합을 층 단위 몬테카를로 추정으로 대체한다. 각 층에서 t_l 개의 노드를 중요도 분포 $q(u) \propto \|A(:, u)\|^2$ 로부터 한 번 추출하며, 평균은 이웃 수가 아니라 추출 개수 t_l 로 나눈다.

- 층 단위 추출이 GraphSAGE 의 노드 단위 추출과 어떻게 다른지 서술하시오.
- 다섯 노드에 대한 중요도 분포 $q(u)$ 를 계산하시오.
- 주어진 추출 집합($t_l = 2$)에 대하여 $h^{(1)}(A)$ 의 추정값을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} -2 \\ 4 \\ 4 \\ -1 \\ -2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In node-wise sampling, each node samples its own neighbours, so the cost grows exponentially with depth.
 - FastGCN samples a fixed-size set of nodes once per layer, shared by all nodes in that layer.
 - Therefore the cost grows only linearly with depth instead of exponentially.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 뽑기는 노드마다 제 이웃을 뽑아서, 층이 깊어질수록 비용이 지수로 커져요.
 - FastGCN 은 층마다 정해진 개수를 한 번만 뽑고, 그 층의 모든 노드가 같이 써요.
 - 그래서 비용이 지수가 아니라 층 수에 비례해서만 늘어요.

ENG) b) $q(A) = 0.0889$, $q(B) = 0.0444$, $q(C) = 0.1889$, $q(D) = 0.1889$, $q(E) = 0.4889$

ENG) c) $h^{(1)}(A) = 0$

ENG)

3. (ASGCN) Consider the undirected graph G with adjacency matrix A and node feature vector $h^{(0)}$ below. ASGCN rewrites a GCN layer as an expectation:

$$h^{(l+1)}(v_i) = \sigma(W^{(l)} N(v_i) E_{p(u_j | v_i)}[h^{(l)}(u_j)])$$

where $\tilde{A} = D^{-1}A$, $N(v_i) = \sum_j \tilde{A}_{ij}$, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$, $W^{(l)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- What does the proposal distribution depend on in ASGCN that it does not in FastGCN?
- Calculate $N(v_i)$ and $p(u_j | v_i)$ for the parent node $v_i = E$.
- Calculate $E_{p(u_j | E)}[h^{(0)}(u_j)]$ and the resulting $h^{(1)}(E)$.

KOR)

문제 11 과 동일한 그래프와 특징 벡터를 고려한다.

ASGCN 은 GCN 한 층을 확률 분포에 대한 기댓값으로 다시 쓴다. 여기서 $N(v_i) = \sum_j \tilde{A}_{ij}$ 는 정규화 계수이고, $p(u_j | v_i) = \tilde{A}_{ij} / N(v_i)$ 는 부모 노드 v_i 가 주어졌을 때 노드 u_j 를 추출할 확률이다.

- ASGCN 의 제안 분포가 FastGCN 과 달리 무엇에 의존하는지 서술하시오.
- 주어진 부모 노드에 대한 $N(v_i)$ 와 $p(u_j | v_i)$ 를 계산하시오.
- 해당 기댓값과 그 결과로 얻어지는 $h^{(1)}$ 을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$h^{(0)} = \begin{bmatrix} 4 \\ 4 \\ 1 \\ 2 \\ 3 \end{bmatrix}$$

풀이**ENG)**

- Write these three sentences.
 - In FastGCN the sampling distribution is fixed in advance and does not depend on the parent nodes.
 - In ASGCN the proposal distribution is conditioned on the nodes of the upper layer.
 - This makes almost every sampled node useful and reduces the variance of the estimate.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - FastGCN 의 뽑기 확률은 미리 정해져 있고 부모 노드와 상관이 없어요.
 - ASGCN 은 뽑기 확률을 윗층 노드에 맞춰 정해요.
 - 그래서 뽑은 노드가 거의 다 쓸모 있고, 추정값의 흔들림이 줄어요.

ENG) b) $N(E) = 1$, $p(A|E) = 0.5$, $p(D|E) = 0.5$

ENG) c) $E = 3$, $h_1(E) = 3$

ENG)

4. (APPPNP) Given a graph with an adjacency matrix A and a prediction matrix H produced by an MLP as follows:

APPPNP propagates the predictions with a teleport probability α :

$$Z^{(0)} = H, \quad Z^{(k+1)} = (1 - \alpha) \tilde{A} Z^{(k)} + \alpha H$$

where $\tilde{A} = D^{-1}A$ and $\alpha = 0.2$. No nonlinearity is applied between steps.

- Explain the teleport mechanism and why it prevents over-smoothing.
- Calculate $\tilde{A}$ and $Z^{(1)}$.
- Calculate $Z^{(2)}$.

KOR)

인접행렬 A 와 다층 퍼셉트론이 산출한 예측 행렬 H 가 주어졌다.

APPPNP 는 순간이동 확률 α 를 사용하여 예측을 전파한다. 전파 단계 사이에는 비선형 함수를 적용하지 않는다.

- 개인화 PageRank 의 순간이동 기법을 설명하고, 그것이 과평활을 막는 이유를 서술하시오.
- $\tilde{A}$ 와 $Z^{(1)}$ 을 계산하시오.
- $Z^{(2)}$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - At every propagation step the walk returns to the root node with probability alpha. This is the teleport mechanism.
 - Because a fixed fraction of the mass is pulled back at every step, the distribution stays local.
 - So we can use many propagation steps without over-smoothing, and propagation has no extra parameters.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 퍼뜨리는 걸음마다 확률 알파로 출발 노드로 되돌아가요. 이것이 순간이동 장치예요.
 - 매 걸음 일정 비율이 되돌아오니까 분포가 출발점 근처에 머물러요.
 - 그래서 많이 퍼뜨려도 과평활이 안 생기고, 퍼뜨리는 데에 추가 파라미터도 없어요.

ENG) b) $\tilde{A} = [0, 0.5, 0.5, 0]; [0.5, 0, 0, 0.5]; [0.5, 0, 0, 0.5]; [0, 0.5, 0.5, 0]$

ENG) $Z^1 = [0.4, 0.2, 0, 0.4]$

ENG) c) $Z^2 = [0.08, 0.52, 0.32, 0.08]$

ENG)

5. (GPR-GNN) Given a graph with an adjacency matrix A and hidden features $H^{(0)}$ as follows:

GPR-GNN separates feature extraction from topological propagation:

$$H^{(k)} = \tilde{A} H^{(k-1)}, \quad Z = \sum_{k=0}^K \gamma_k H^{(k)}$$

where $\tilde{A} = D^{-1}A$, $K = 2$, $\gamma_0 = 0.7$, $\gamma_1 = 0.2$, $\gamma_2 = -0.3$.

- What can GPR-GNN do that APPNP cannot, and why do negative γ_k matter?
- Calculate $H^{(1)}$ and $H^{(2)}$.
- Calculate Z .

KOR)

인접행렬 A 와 신경망이 산출한 은닉 특징 $H^{(0)}$ 이 주어졌다.

GPR-GNN 은 특징 추출과 위상 전파를 분리한다. $\tilde{A}$ 를 반복 적용하여 $H^{(k)}$ 를 얻고, 학습된 가중치 γ_k 로 가중합한다. 본 문항에서는 $K = 2$ 이며 $\gamma_0, \gamma_1, \gamma_2$ 가 주어진다.

- GPR-GNN 이 APPNP 와 달리 할 수 있는 것은 무엇이며, γ_k 가 음수가 될 수 있다는 점이 이질적 그래프에서 왜 중요한지 서술하시오.
- $H^{(1)}$ 과 $H^{(2)}$ 를 계산하시오.
- Z 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -1 \\ 1 \\ -2 \\ 2 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - APPNP fixes the coefficients to alpha times (1-alpha) to the power k, which are always positive and decreasing.
 - GPR-GNN learns the weights, and they are allowed to be negative.
 - A negative weight subtracts that hop, so the model can act as a high-pass filter on heterophilic graphs.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - APPNP 는 계수를 알파 곱하기 (1-알파)의 k제곱으로 못 박아요. 늘 양수이고 줄어들어요.
 - GPR-GNN 은 그 무게를 학습하고, 음수도 될 수 있어요.
 - 음수 무게는 그 걸음을 빼요. 그래서 이질 그래프에서 고주파 필터처럼 동작할 수 있어요.

ENG) b) $H_1 = [-0.5, -1.5, 0.6667, -2]$, $H_2 = [-0.4167, 0.0833, -1.3333, 0.6667]$

ENG) c) $Z = [-0.675, 0.375, -0.8667, 0.8]$

ENG)

6. (MixHop) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

A MixHop layer concatenates several powers of the adjacency matrix:

$$H^{(i+1)} = \parallel_{j \in P} \sigma(\hat{A}^j H^{(i)} W_j^{(i)})$$

where $P = \{0, 1, 2\}$, $\hat{A} = D^{-1}A$, $W_j^{(i)} = 1$ and $\text{ReLU}(x) = \max(0, x)$.

- State Theorem 1 of MixHop about the two-hop Delta Operator.
- Calculate $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$ and $\hat{A}^2 H^{(0)}$.
- Calculate $H^{(1)}$ and the Delta Operator $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

MixHop 한 층은 인접행렬의 여러 거듭제곱 $\hat{A}^j$ ($j \in P = \{0, 1, 2\}$)를 각각 계산한 뒤 열 방향으로 이어 붙인다. 본 문항에서 가중치 행렬은 모두 1 로 둔다.

- 두 걸음 델타 연산자에 관한 MixHop 의 정리 1 을 서술하고, 보통의 GCN 이 층을 무한히 쌓아도 이를 표현할 수 없는 이유를 설명하시오.
- $\hat{A}^0 H^{(0)}$, $\hat{A}^1 H^{(0)}$, $\hat{A}^2 H^{(0)}$ 을 계산하시오.
- $H^{(1)}$ 과 델타 연산자 $\sigma(\hat{A} H^{(0)}) - \sigma(\hat{A}^2 H^{(0)})$ 를 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 3 \\ -3 \\ 1 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Theorem 1 says that a vanilla GCN cannot represent the two-hop Delta Operator, even with infinitely many layers.
 - Stacking GCN layers collapses to $\hat{A}$ to the power l times W , so the intermediate hops are never kept separately.
 - MixHop computes each power separately and concatenates them, so a later layer can subtract one from another.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 정리 1 은 보통 GCN 이 두 걸음 델타 연산자를 표현할 수 없다고 말해요. 층을 무한히 쌓아도요.
 - GCN 층을 쌓으면 A 에 1제곱 곱하기 W 꼴로 뭉쳐져서, 중간 걸음들이 따로 남지 않아요.
 - MixHop 은 거듭제곱마다 따로 구해서 나란히 붙여요. 그래서 뒤 층이 하나에서 다른 하나를 뺄 수 있어요.

ENG) b) $A^0 H = [3, -3, 1, 0]$, $A^1 H = [-1, 1.5, 1.5, -1]$, $A^2 H = [1.5, -1, -1, 1.5]$

ENG) c) $H^1 = \text{concatenation of the three blocks: } [3, 0, 1, 0] \parallel [0, 1.5, 1.5, 0] \parallel [1.5, 0, 0, 1.5]$

KOR) c) H1 = 세 조각을 이어 붙여요: $[3, 0, 1, 0] \mid [0, 1.5, 1.5, 0] \mid [1.5, 0, 0, 1.5]$

ENG) $\Delta = [-1.5, 1.5, 1.5, -1.5]$

ENG)

7. (PairNorm) After one GCN layer the node features of a four-node graph are

PairNorm normalizes them with a centering step and a scaling step:

$$x_i^c = x_i - (1/n) \sum_i x_i \quad (\text{Center})$$

$$x_i = s \cdot x_i^c / \sqrt{(1/n) \sum_i \|x_i^c\|_2^2} \quad (\text{Scale})$$

with $s = 1$ and $n = 4$.

- Explain node-wise and feature-wise over-smoothing, and what PairNorm keeps constant.
- Calculate the centered features.
- Calculate the scaling denominator and the final x_i .

KOR)

GCN 한 층을 통과한 뒤의 노드 특징 행렬 X 가 주어졌다. 행은 노드, 열은 특징 차원이다.

PairNorm 은 중심화 단계와 크기 조정 단계로 정규화한다. 중심화는 노드들에 대한 평균을 빼는 것이고, 크기 조정은 중심화된 벡터들의 노름 제곱 평균의 제곱근으로 나누는 것이다. $s = 1, n = 4$ 로 한다.

- 노드 단위 과평활과 특징 단위 과평활을 각각 설명하고, PairNorm 이 층에 걸쳐 일정하게 유지하는 양이 무엇인지 서술하시오.
- 중심화된 특징을 계산하시오.
- 크기 조정의 분모와 최종 x_i 를 계산하시오.

$$X = \begin{bmatrix} -2 & 4 \\ 1 & -1 \\ -1 & 1 \\ -1 & 3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Node-wise over-smoothing means the features of connected nodes become too similar.
 - Feature-wise over-smoothing means all node features become indistinguishable across the whole graph.
 - PairNorm keeps the total pairwise squared distance between node representations constant across layers.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 노드 단위 과평활은 이어진 노드들의 특징이 너무 비슷해지는 것이에요.
 - 특징 단위 과평활은 그래프 전체에서 모든 노드 특징이 구별이 안 되게 되는 것이에요.
 - PairNorm 은 층을 지나도 노드 사이 거리 제곱의 합을 일정하게 지켜요.

ENG) b) Mean = [-0.75, 1.75], centered = [-1.25, 2.25]; [1.75, -2.75]; [-0.25, -0.75]; [-0.25, 1.25]

KOR) b) 평균 = [-0.75, 1.75], 중심을 뺀 것 = [-1.25, 2.25]; [1.75, -2.75]; [-0.25, -0.75]; [-0.25, 1.25]

ENG) c) Scaling denominator = 2.2079, $x = [-0.5661, 1.019]; [0.7926, -1.2455]; [-0.1132, -0.3397]; [-0.1132, 0.5661]$

KOR) c) 분모 = 2.2079, $x = [-0.5661, 1.019]; [0.7926, -1.2455]; [-0.1132, -0.3397]; [-0.1132, 0.5661]$

ENG)

8. (DropEdge) Consider the complete graph K_4 on nodes A, B, C and D with the adjacency matrix A and initial node feature matrix $H^{(0)}$ below.

DropEdge keeps each undirected edge independently with probability $1 - p$ at every epoch:

$$H^{(1)} = \sigma((D^{(t)})^{-1} A^{(t)} H^{(0)})$$

where $A^{(t)}$ and $D^{(t)}$ are rebuilt from the surviving edges only, $p = 1/3$, and $\text{ReLU}(x) = \max(0, x)$.

- Which two problems does DropEdge target, and how does it differ from Dropout?
- Calculate the expected number of surviving edges, and $H^{(1)}$ on the full graph.
- Suppose the edges (C, D) and (A, D) are dropped. Recalculate $H^{(1)}$.

KOR)

노드 A, B, C, D 로 이루어진 완전그래프 K_4 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

DropEdge 는 매 에폭마다 각 무방향 간선을 확률 $1-p$ 로 독립적으로 유지한다. 이때 $A^{(t)}$ 와 $D^{(t)}$ 는 살아남은 간선만으로 다시 구성한다. $p = 1/3$ 으로 한다.

- DropEdge 가 목표로 하는 두 가지 문제를 쓰고, Dropout 과 어떻게 다른지 서술하시오.
- 살아남은 간선 수의 기댓값과, 간선을 제거하지 않은 원래 그래프에서의 $H^{(1)}$ 을 계산하시오.
- 주어진 두 간선이 제거되었을 때의 $H^{(1)}$ 을 다시 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -2 \\ 2 \\ 1 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - DropEdge targets over-fitting and over-smoothing.
 - A different random subgraph is used at every epoch, which works as data augmentation on the graph.
 - Dropout zeroes entries of the feature tensor, while DropEdge removes edges of the adjacency matrix.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - DropEdge 는 과적합과 과평활을 노려요.
 - 판마다 다른 부분 그래프를 써요. 그래프에 자료를 늘리는 효과가 나요.
 - Dropout 은 특징 값을 0 으로 꺼요. DropEdge 는 인접행렬의 선을 지워요.

ENG) b) Expected number of surviving edges = 4, $H_1 = [1, 0, 0, 0.3333]$

KOR) b) 남는 선 수의 기댓값 = 4, $H_1 = [1, 0, 0, 0.3333]$

ENG) c) $H_1 = [1.5, 0, 0, 2]$

ENG)

9. (Node2vec) Consider an undirected graph G given in the following figure. A random walk has just moved from node A to node B , with $p = 2$ and $q = 0.5$.

The unnormalized transition probability from B to a next node x is $\pi_{Bx} = \alpha_{pq}(A, x)$, where $\alpha = 1/p$ if $d(A, x) = 0$, $\alpha = 1$ if $d(A, x) = 1$, and $\alpha = 1/q$ if $d(A, x) = 2$.

- Explain BFS and DFS, and explain which one a small q makes the walk behave like.
- List all possible next nodes from node B and calculate π_{Bx} .
- Calculate the normalized transition probabilities.

KOR)

다음 그림의 무방향 그래프 G 를 고려한다. 임의보행이 노드 A 에서 노드 B 로 이동하여 현재 B 에 있으며, $p = 2, q = 0.5$ 이다.

B 에서 다음 노드 x 로의 비정규화 전이확률은 $\pi_{Bx} = \alpha_{pq}(A, x)$ 이며, α 는 직전 노드 A 로부터의 최단경로 거리에 따라 결정된다.

- BFS 와 DFS 를 설명하고, q 가 작을 때 보행이 둘 중 어느 쪽처럼 동작하는지 서술하시오.
- 노드 B 에서 이동 가능한 모든 노드를 열거하고 비정규화 전이확률 π_{Bx} 를 계산하시오.
- 정규화된 전이확률을 계산하시오.




Figure 1. Graph G

풀이

ENG)

- Write these three sentences.
 - BFS explores the immediate neighbourhood first, so the embedding captures the structural role of a node.
 - DFS moves far away from the source, so the embedding captures community membership.
 - A small q makes $1/q$ large, so the walk moves outward and behaves like DFS.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - BFS 는 바로 옆 이웃부터 훑어요. 그래서 임베딩이 노드의 구조적 역할을 담아요.
 - DFS 는 출발점에서 멀리 가요. 그래서 임베딩이 어느 동네 소속인지를 담아요.
 - q 가 작으면 $1/q$ 가 커져서 걸음이 바깥으로 나가요. DFS 처럼 움직여요.

ENG) b) $\pi(B \rightarrow A) = 0.5$, $\pi(B \rightarrow C) = 1$, $\pi(B \rightarrow E) = 2$

ENG) c) $P(A) = 0.1429$, $P(C) = 0.2857$, $P(E) = 0.5714$

ENG)

10. (LINE) Consider an undirected graph G with node embeddings

$$u_A = 1, u_B = 0.5, u_C = -0.5, u_D = -1$$

and context embeddings

$$u'_A = 0.5, u'_B = 1, u'_C = -1, u'_D = -0.5.$$

The second-order proximity is $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$. Given $e^{0.25} = 1.28$, $e^{0.5} = 1.65$, $e^{-0.25} = 0.78$, $e^{-0.5} = 0.61$.

- What is second-order proximity, and how does it differ from first-order proximity?
- Calculate $p_2(A|B)$, $p_2(B|B)$, $p_2(C|B)$ and $p_2(D|B)$.

KOR)

노드 임베딩 u 와 맥락 임베딩 u' 가 주어진 무방향 그래프 G 를 고려한다.

2차 근접도는 $p_2(j|x) = \exp(u'_j u_x) / \sum_k \exp(u'_k u_x)$ 로 정의한다. 지수 함수 값은 문제에 주어진 표를 사용한다.

- 2차 근접도란 무엇이며 1차 근접도와 어떻게 다른지 서술하시오.
- 주어진 기준 노드에 대하여 네 노드의 p_2 를 계산하시오.

풀이

ENG)

- Write these three sentences.
 - First-order proximity is the similarity between two nodes that are directly connected by an edge.
 - Second-order proximity is the similarity between two nodes that share many neighbours, even without an edge.
 - So LINE gives each node two vectors: its own embedding and its context embedding.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 1차 근접도는 선으로 직접 이어진 두 노드 사이의 비슷함이에요.
 - 2차 근접도는 이웃을 많이 공유하는 두 노드의 비슷함이에요. 선이 없어도 돼요.
 - 그래서 LINE 은 노드마다 벡터를 두 개 뒹요. 자기 벡터와 맥락 벡터예요.

ENG) b) $p_2(A|B) = 0.2963$, $p_2(B|B) = 0.3819$, $p_2(C|B) = 0.1412$, $p_2(D|B) = 0.1806$

ENG)

11. (GCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the hidden layer of a GCN model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}),$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how information is propagated in a GCN layer.
- Calculate $\tilde{A}$.
- Calculate the output of the GCN model at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCN 모형의 층 (k) 에서의 은닉층은 $H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)})$ 로 계산된다고 가정한다. 여기서 $\tilde{A} = D^{-1}A$ 는 정규화된 인접행렬이고 σ 는 ReLU 이다.

- GCN 한 층에서 정보가 어떻게 전파되는지 설명하시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서 GCN 모형의 출력을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 0 \\ 4 \\ 0 \\ -1 \\ -3 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In one layer each node aggregates the features of its direct neighbours and takes the average.
 - The row-normalized matrix $\tilde{A}$ equals $D^{-1}A$, which performs this averaging.
 - After k layers a node has received information from all nodes within k hops.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 한 층에서 노드는 바로 옆 이웃의 특징을 모아 평균을 내요.
 - 행 정규화 행렬 $\tilde{A}$ 는 D 의 역행렬 곱하기 A 이고, 그것이 평균을 내 줘요.
 - k 개 층을 지나면 노드는 k 걸음 안의 모든 노드 정보를 받아요.

ENG) b) $\tilde{A} = [0, 0.5, 0.5, 0, 0]; [0.3333, 0, 0, 0.3333, 0.3333]; [0.3333, 0, 0, 0.3333, 0.3333]; [0, 0.5, 0.5, 0, 0]; [0, 0.5, 0.5, 0, 0]$

ENG) c) $H_1 = [2, 0, 0, 2, 2]$

ENG)

12. (GraphSAGE) Consider an undirected graph G of five nodes given in the following figure. Each node has initial features that are the numbers standing next to it. According to the GraphSAGE model with an AGGREGATE that is a MEAN function, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i) \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is the main idea behind GraphSAGE, and how does it differ from traditional GCNs?
- Calculate the feature of each node at $k = 1$.
- Calculate a graph-level embedding h_G by using a 'Mean' global pooling when $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 5개)를 고려한다. 각 노드 옆의 수가 초기 특징이다.

집계 함수가 평균인 GraphSAGE 모형에서, 노드 i 의 층 k 특징은 이웃의 평균을 자신의 특징에 이어 붙인 뒤 ReLU를 적용하여 갱신된다.

- GraphSAGE의 핵심 착상은 무엇이며 기존 GCN과 어떻게 다른지 서술하시오.
- $k = 1$ 에서 각 노드의 특징을 계산하시오.
- $k = 1$ 일 때 평균 전역 풀링으로 그래프 수준 임베딩 h_G 를 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE learns an aggregator function instead of a fixed embedding for each node.
 - It samples a fixed number of neighbours, so it can be trained in mini-batches on very large graphs.
 - A GCN is transductive, but GraphSAGE is inductive, so it can embed a node that was never seen in training.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE는 노드마다 고정된 벡터를 배우는 대신 모으는 함수를 배워요.
 - 이웃을 정해진 개수만 뽑아요. 그래서 아주 큰 그래프에서도 미니배치로 학습할 수 있어요.
 - GCN은 전이적이고 GraphSAGE는 귀납적이에요. 그래서 학습 때 못 본 노드도 벡터를 만들 수 있어요.

ENG) b) $h(A) = [3, 0.3333]$, $h(B) = [4, 1]$, $h(C) = [0, 2.5]$, $h(D) = [0, 3.5]$, $h(E) = [2, 2]$

ENG) c) $hG = [1.8, 1.8667]$

ENG)

13. (ClusterGCN) Consider an undirected graph G of six nodes given in the following figure. The graph G contains two clusters G_1 and G_2 . Each node has initial features that are the numbers standing next to it. According to the ClusterGCN model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- What is mini-batch training, and why does ClusterGCN need it?
- Calculate the output representations of all nodes at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 는 두 개의 군집 G_1 과 G_2 를 포함하며, 각 노드 옆의 수가 초기 특징이다.

ClusterGCN 모형에서는 이웃 중 자신과 같은 군집에 속한 노드만 평균에 포함한다.

- 미니배치 학습이란 무엇이며 ClusterGCN 이 이를 필요로 하는 이유를 서술하시오.
- 층 $k = 1$ 에서 모든 노드의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - Mini-batch training updates the parameters using a small subset of the data at a time.
 - A large graph does not fit in memory, so ClusterGCN partitions the graph into densely connected clusters.
 - A good partition keeps most edges inside a batch, so little information is lost at the boundary.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 미니배치 학습은 한 번에 자료의 일부만 써서 파라미터를 고쳐요.
 - 큰 그래프는 메모리에 안 들어가요. 그래서 ClusterGCN 은 안쪽이 촘촘한 덩어리로 나뉘요.
 - 잘 나누면 선 대부분이 배치 안에 남아서 경계에서 잃는 정보가 적어요.

ENG) b) $h(A) = [0, 4]$, $h(B) = [4, 0]$, $h(C) = [4, 0]$, $h(D) = [2, 4]$, $h(E) = [0, 4]$, $h(F) = [4, 1]$

ENG)

14. (GraphSAINT) Consider an undirected graph G of six nodes given in the following figure. The graph G has a sampled subgraph G_1 . Each node has initial features that are the numbers standing next to it. According to the GraphSAINT model, the feature of a node i at layer k can be updated as:

$$h_{N(i)}^{(k)} = \text{MEAN}(\{ h_u^{(k-1)}, \forall u \in N(i), G_u = G_i \})$$

$$h_i^{(k)} = \text{ReLU}(h_i^{(k-1)} \parallel h_{N(i)}^{(k)})$$

where $\parallel$ is a concatenation and $\text{ReLU}(x) = \max(0, x)$.

- How does GraphSAINT's sampling differ from node-wise or layer-wise sampling?
- Calculate the output representations of nodes A, B, C and D at layer $k = 1$.

KOR)

다음 그림의 무방향 그래프 G (노드 6개)를 고려한다. 그래프 G 에는 추출된 부분그래프 G_1 이 주어져 있으며, 각 노드 옆의 수가 초기 특징이다.

GraphSAINT 모형에서는 이웃 중 같은 부분그래프에 속한 노드만 평균에 포함한다.

- GraphSAINT의 추출 전략이 노드 단위 또는 층 단위 추출 방식과 어떻게 다른지 서술하시오.
- 층 $k = 1$ 에서 노드 A, B, C, D의 출력 표현을 계산하시오.




Figure. Graph G

풀이

ENG)

- Write these three sentences.
 - GraphSAGE and FastGCN sample while building the layers, so sampling is repeated at every layer.
 - GraphSAINT samples a subgraph first and then builds the full GNN on that subgraph.
 - So the cost does not grow with depth, and normalization coefficients correct the sampling bias.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - GraphSAGE와 FastGCN은 층을 쌓으면서 뽑아요. 그래서 층마다 뽑기를 되풀이해요.
 - GraphSAINT는 부분 그래프를 먼저 뽑고 그 위에 GNN을 통째로 올려요.
 - 그래서 깊어져도 비용이 안 늘고, 정규화 계수로 뽑기의 치우침을 바로잡아요.

ENG) b) $h(A) = [3, 1]$, $h(B) = [1, 3]$, $h(C) = [3, 1]$, $h(D) = [3, 1]$

ENG)

15. (JK Network) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a JK network model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \max(\sigma(\tilde{A} H^{(0)}), \sigma(\tilde{A} H^{(1)}), \dots, \sigma(\tilde{A} H^{(k-1)}))$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain how Jumping Knowledge Networks help mitigate the over-smoothing problem.
- Calculate $\tilde{A}$ and $H^{(1)}$.
- Calculate the output representations at layer $k = 2$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

JK 신경망의 층 (k) 출력은 $\sigma(\tilde{A} H^{(0)})$ 부터 $\sigma(\tilde{A} H^{(k-1)})$ 까지의 원소별 최댓값으로 계산된다고 가정한다.

- Jumping Knowledge 신경망이 깊은 GCN 의 과평활 문제를 어떻게 완화하는지 설명하시오.
- $\tilde{A}$ 와 $H^{(1)}$ 을 계산하시오.
- 층 $k = 2$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -1 \\ 4 \\ 2 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - In a deep GCN every node repeatedly averages its neighbours, so all representations become similar. This is over-smoothing.
 - JKNet keeps the representation of every layer and combines them at the end by max, concatenation or an LSTM.
 - The best depth is different for each node, so each node can select the depth that suits it.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 에서는 노드가 이웃 평균을 거듭 내서 표현들이 다 비슷해져요. 이것이 과평활이에요.
 - JKNet 은 모든 층의 표현을 들고 있다가 끝에서 최댓값, 이어 붙이기, LSTM 으로 합쳐요.
 - 알맞은 깊이는 노드마다 달라요. 그래서 노드마다 자기에게 맞는 깊이를 고를 수 있어요.

ENG) b) $\tilde{A} = [0, 0.3333, 0.3333, 0, 0.3333]; [0.5, 0, 0, 0, 0.5]; [0.3333, 0, 0, 0.3333, 0.3333]; [0, 0, 1, 0, 0]; [0.3333, 0.3333, 0.3333, 0, 0]$

ENG) H1 = [0.6667, 0, 0.6667, 4, 1.3333]

ENG) c) H2 = [0.6667, 1, 2, 4, 1.3333]

ENG)

16. (GCNII) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a GCNII model of all nodes at layer (k) can be calculated as:

$$H^{(k)} = \sigma[((1 - \beta) I_n) \cdot ((1 - \alpha) \tilde{A} \cdot H^{(k-1)} + \alpha H^{(0)})]$$

where $\tilde{A} = D^{-1}A$, I_n is the identity matrix, $\alpha = 0.5$, $\beta = 0.4$, and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- What are the two major components introduced in GCNII to overcome the depth limitation?
- Calculate $\tilde{A}$.
- Calculate the output representations at layer $k = 1$.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

GCNII 모형의 층 (k) 출력은 $H^{(k)} = \sigma[((1-\beta)I_n) \cdot ((1-\alpha) \tilde{A} H^{(k-1)} + \alpha H^{(0)})]$ 로 계산된다고 가정한다. I_n 은 단위행렬이며 α 와 β 는 문제에 주어진 값을 사용한다.

- GCNII 가 GCN 의 깊이 한계를 극복하기 위해 도입한 두 가지 주요 구성 요소를 쓰시오.
- $\tilde{A}$ 를 계산하시오.
- 층 $k = 1$ 에서의 출력 표현을 계산하시오.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} 1 \\ -3 \\ 3 \\ 4 \\ -1 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - The two components are the initial residual connection and the identity mapping.
 - The initial residual connection adds a fraction alpha of the input H zero back at every layer.
 - The identity mapping keeps the weight matrix close to the identity, so a deep model is not destroyed.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 두 장치는 초기 잔차 연결과 항등 사상이에요.
 - 초기 잔차 연결은 층마다 입력 $H^{(0)}$ 의 일부를 알파만큼 다시 더해요.
 - 항등 사상은 가중치 행렬을 단위행렬에 가깝게 뒹요. 그래서 깊어져도 신호가 안 망가져요.

ENG) b) $A_{ilde} = [0, 0, 0.5, 0.5, 0]; [0, 0, 0.5, 0, 0.5]; [0.3333, 0.3333, 0, 0.3333, 0]; [0.3333, 0, 0.3333, 0, 0.3333]; [0, 0.5, 0, 0.5, 0]$

ENG) c) $H_1 = [1.35, 0, 1.1, 1.5, 0]$

ENG)

17. (DeepGCN) Given a graph with an adjacency matrix A and initial node feature matrix $H^{(0)}$ as follows:

Assume that the output of a DeepGCN model with a residual connection at layer (k) is:

$$H^{(k)} = \sigma(\tilde{A} \cdot H^{(k-1)}) + H^{(k-1)}$$

where $\tilde{A} = D^{-1}A$ and σ is a ReLU function $\text{ReLU}(x) = \max(0, x)$.

- Explain why a residual connection allows a GCN to be made deeper.
- Calculate the output representations at layer $k = 1$ and $k = 2$.
- Compare $H^{(1)}$ with the output of a plain GCN without the residual connection.

KOR)

인접행렬 A 와 초기 노드 특징 행렬 $H^{(0)}$ 이 주어졌다.

잔차 연결을 갖는 DeepGCN 의 층 (k) 출력은 $H^{(k)} = \sigma(\tilde{A} H^{(k-1)}) + H^{(k-1)}$ 로 계산된다고 가정한다. 덧셈은 ReLU 적용 이후에 이루어진다.

- 잔차 연결이 GCN 을 더 깊게 쌓을 수 있게 하는 이유를 설명하시오.
- 층 $k = 1$ 과 $k = 2$ 에서의 출력 표현을 계산하시오.
- 잔차 연결이 없는 보통의 GCN 출력과 $H^{(1)}$ 을 비교하시오.

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$$

$$H^{(0)} = \begin{bmatrix} -3 \\ 1 \\ 2 \\ 0 \end{bmatrix}$$

풀이

ENG)

- Write these three sentences.
 - Deep GCNs suffer from vanishing gradients and over-smoothing, so adding layers makes the model worse.
 - A residual connection passes the input forward unchanged, so each layer only has to learn the change.
 - If no change is useful the layer can output zero, and gradients also flow back through the skip path.

KOR)

- 는 영어로 쓴다. 위 세 문장을 그대로 적으면 된다.
 - 깊은 GCN 은 기울기 소실과 과평활을 겪어요. 그래서 층을 더하면 오히려 나빠져요.
 - 잔차 연결은 입력을 그대로 앞으로 보내요. 그래서 층은 바뀌는 양만 배우면 돼요.
 - 바꿀 게 없으면 층은 0 을 내보내면 돼요. 기울기도 그 지름길로 되돌아 흘러요.

ENG) b) $H_1 = [-2, 1, 2, 0]$

ENG) $H_2 = [-1, 1, 2, 0]$

ENG) c) Plain GCN without residual: $H_1 = [1, 0, 0, 0]$ (the node's own value and negatives disappear)

KOR) c) 잔차 없는 GCN 의 $H_1 = [1, 0, 0, 0]$ (잔차가 없으면 자기 값과 음수가 사라져요)